

5.1. Tổng quan và Phân tích các phương pháp tiếp cận (Literature Review)

Dự báo lưu lượng và tình trạng ùn tắc giao thông là một bài toán chuỗi thời gian (Time-series forecasting) mang tính thách thức cao do bản chất ngẫu nhiên (stochastic) và độ phức tạp về mặt không gian của mạng lưới đường bộ. Để đánh giá tính khả thi và hiệu quả của các kiến trúc dự báo, nghiên cứu này tiến hành phân tích và so sánh các phương pháp tiếp cận hiện hành dựa trên ba tiêu chí cốt lõi: **(1) Khả năng bắt giữ phụ thuộc thời gian (Temporal dependence capture)**, **(2) Năng lực xử lý dữ liệu phi cấu trúc và đa phương thức (Unstructured/Multimodal data handling)**, và **(3) Mục tiêu tối ưu hóa (Optimization objectives)**.

Việc phân tích các phương pháp từ cổ điển đến hiện đại giúp làm rõ những rào cản kỹ thuật hiện tại, từ đó củng cố cơ sở khoa học cho việc đề xuất kiến trúc Học chuyển giao lai (Hybrid Transfer RL) trong đề án này.

5.1.1. Tiếp cận dựa trên Thống kê truyền thống (ARIMA, SARIMA)

a. Nguyên lý hoạt động và Cơ sở toán học Phương pháp tự hồi quy tích hợp trung bình trượt (Autoregressive Integrated Moving Average - ARIMA) và biến thể có tính mùa vụ (SARIMA) là những mô hình thống kê kinh điển nhất trong phân tích chuỗi thời gian. Nguyên lý cốt lõi của ARIMA dựa trên giả định về **tính dừng (stationarity)** của dữ liệu. Nghĩa là, các đặc trưng thống kê của chuỗi thời gian (như kỳ vọng, phương sai) không thay đổi theo thời gian.

Mô hình thiết lập dự báo dựa trên một tổ hợp tuyến tính bao gồm ba thành phần:

- **AR (Autoregressive - Tự hồi quy):** Biểu diễn giá trị hiện tại như một hàm tuyến tính của các giá trị trong quá khứ, giúp bắt giữ quán tính của dòng xe.
- **I (Integrated - Tích hợp):** Sử dụng sai phân (differencing) để triệt tiêu xu hướng (trend), ép chuỗi dữ liệu giao thông phi dừng về trạng thái dừng.
- **MA (Moving Average - Trung bình trượt):** Khai thác mối liên hệ phụ thuộc giữa giá trị quan sát hiện tại và các sai số ngẫu nhiên (white noise) từ các dự báo trước đó.


b. Ưu điểm Đối với tiêu chí thứ nhất (bắt giữ phụ thuộc thời gian), ARIMA thực hiện rất tốt trong điều kiện dòng lưu lượng giao thông ở trạng thái dòng tự do (free-flow) hoặc biến thiên theo chu kỳ ổn định. Mô hình có tính minh bạch toán học (White-box) cao, dễ dàng diễn giải các hệ số tác động và yêu cầu chi phí tính toán cực kỳ thấp.

c. Hạn chế thực tiễn và Sự thất bại trước thảm họa giao thông Tuy nhiên, khi đối chiếu với thực tiễn mạng lưới giao thông tại TP.HCM, mô hình thống kê truyền thống bộc lộ những khuyết điểm chí mạng:

1. **Sự bất lực trước "Điểm gãy" phi tuyến tính (Non-linear Structural Breaks):** ARIMA bị ràng buộc bởi giả định quan hệ tuyến tính. Trong thực tế, sự hình thành kẹt xe thảm họa (Mức 4, Mức 5) không diễn ra từ từ mà là một sự suy sụp cấu trúc đột ngột (ví dụ: một vụ tai nạn hoặc mưa lớn đổ xuống khiến vận tốc giảm từ 40 km/h xuống 5 km/h chỉ trong 2 phút). Khi đối mặt với biến động này, kết quả dự báo

của ARIMA bị **trễ pha (Lagging effect)** nghiêm trọng. Mô hình thường dự báo kẹt xe *sau khi* kẹt xe đã thực sự xảy ra, khiến giá trị cảnh báo sớm bị triệt tiêu hoàn toàn.


2. **Khả năng xử lý dữ liệu ngoại lai kém (Tiêu chí 2):** ARIMA chỉ chấp nhận dữ liệu đầu vào là một chuỗi giá trị đơn biến (Univariate) hoặc đa biến tuyến tính. Nó hoàn toàn bất lực trong việc nhúng (embedding) các dữ liệu phi cấu trúc mang tính tâm lý và không gian như sự thay đổi thời tiết, ID phân vùng địa lý, hay mã loại đường bộ.
3. **Sai lệch Mục tiêu Tối ưu (Tiêu chí 3):** Hàm mục tiêu của ARIMA thường là giảm thiểu sai số toàn phương trung bình (MSE). Điều này buộc mô hình phải bám sát vào nhóm dữ liệu đa số (trạng thái thông thoáng), dẫn đến việc bỏ qua các giá trị ngoại lai (Anomalies) vốn đại diện cho thảm họa giao thông.



Hình 5.1: Biểu đồ minh họa hiện tượng Trễ pha của mô hình ARIMA

5.1.2. Tiếp cận dựa trên Học sâu (LSTM, CNN, T-GCN)

Sự bùng nổ của Học sâu (Deep Learning - DL) đã mở ra một kỷ nguyên mới cho bài toán dự báo giao thông nhờ khả năng tự động trích xuất các đặc trưng phi tuyến tính phức tạp mà không cần sự can thiệp thủ công từ chuyên gia.



Hình 5.2: Sơ đồ khối kiến trúc LSTM đơn giản

a. Khả năng bắt giữ phụ thuộc thời gian với mạng LSTM Trong các kiến trúc DL, mạng Bộ nhớ ngắn hạn dài (Long Short-Term Memory - LSTM) được xem là tiêu chuẩn vàng cho dữ liệu chuỗi thời gian. Khác với mạng nơ-ron truyền thống, LSTM giải quyết triệt để vấn đề **Tiêu biến đạo hàm (Vanishing Gradient)** nhờ vào cấu trúc "Tế bào nhớ" (Memory cell) và cơ chế các cổng (Gates):


- **Cổng quên (Forget Gate):** Loại bỏ những thông tin không còn giá trị từ quá khứ (ví dụ: dữ liệu vận tốc của 2 tiếng trước không còn ảnh hưởng đến kẹt xe hiện tại).
- **Cổng nhập (Input Gate):** Cập nhật những thông tin mới quan trọng vào trạng thái tế bào.
- **Cổng xuất (Output Gate):** Quyết định thông tin nào sẽ được đưa ra làm đầu ra và chuyển sang bước thời gian tiếp theo.

Cơ chế này cho phép LSTM duy trì sự phụ thuộc xa (Long-term dependencies), giúp mô hình hiểu được xu hướng giao thông kéo dài qua nhiều khung giờ.

b. Khả năng xử lý dữ liệu phi cấu trúc và không gian (CNN, T-GCN) Bên cạnh yếu tố thời gian, các mô hình như Mạng nơ-ron tích chập (CNN) và Mạng tích chập đồ thị (T-GCN) được tích hợp để xử lý **Phụ thuộc không gian (Spatial dependence)**. Trong khi CNN hiệu quả với dữ liệu dạng lưới (Grid-based), T-GCN lại tỏ ra ưu việt trong việc mô hình hóa mạng lưới đường phố dưới dạng một đồ thị (Graph), nơi các nút là các đoạn đường và cạnh là sự kết nối giao thông giữa chúng.

c. Phân tích khuyết điểm: Thiên kiến lớp đa số (Majority Class Bias) Dù mạnh mẽ hơn ARIMA, các mô hình Deep Learning chuẩn vẫn gặp phải một rào cản lớn về **Mục tiêu tối ưu hóa (Tiêu chí 3)** khi đối mặt với dữ liệu mất cân bằng:

1. **Sự thống trị của Hàm Loss chuẩn:** Các mô hình DL thường sử dụng Mean Squared Error (MSE) hoặc Cross-Entropy làm hàm mất mát. Các hàm này tính toán giá trị trung bình trên toàn bộ tập dữ liệu. Vì trạng thái "Thông thoáng" (Lớp 0, 1, 2) chiếm đến 90-95% dữ liệu, mô hình sẽ bị "đánh lừa" rằng việc dự báo đúng lớp đa số là cách nhanh nhất để giảm Loss xuống mức tối thiểu.
2. **Hệ quả "Mù màu" với thảm họa:** Kết quả là mô hình đạt độ chính xác (Accuracy) tổng thể rất cao (thường > 90%), nhưng lại có chỉ số **Recall ở lớp 4 và lớp 5 cực thấp**. Trong thực tế, điều này cực kỳ nguy hiểm: Hệ thống báo cáo đường thông thoáng nhưng thực tế người dùng lại bị kẹt cứng trong một vụ tắc đường vỡ trận. Đây chính là hiện tượng "Học vẹt" theo lớp đa số mà các kiến trúc DL thuần túy khó lòng vượt qua nếu không có sự can thiệp về chiến lược lấy mẫu hoặc hàm phân thưởng.



Hình 5.3: Ma trận nhầm lẫn mô hình DL thuần túy

5.1.3. Đề xuất Kiến trúc Lai (Hybrid SL-to-RL Transfer)

Để khắc phục triệt để sự "trễ pha" của mô hình thống kê (ARIMA) và "thiên kiến lớp đa số" của mô hình Deep Learning chuẩn (LSTM), đề án đề xuất một kiến trúc lai đột phá: **Hybrid SL-to-RL Transfer**. Phương pháp này tái định nghĩa bài toán dự báo giao thông không chỉ là việc khớp đường cong dữ liệu (curve-fitting), mà là một quá trình ra quyết định tối ưu tuần tự (Sequential Decision Making).

Kiến trúc đề xuất là sự giao thoa giữa khả năng trích xuất đặc trưng của **Học có giám sát (Supervised Learning - SL)** và cơ chế định hướng mục tiêu của **Học tăng cường sâu (Deep Reinforcement Learning - DRL)**, bao gồm các thành phần cốt lõi sau:


a. Cấu trúc mạng Trích xuất Đặc trưng Đa nhánh (Multi-branch Fusion Network)

Hệ thống sử dụng một mạng Nơ-ron tùy chỉnh (đóng vai trò là mô hình SL cơ sở và mạng Q-Network sau này) bao gồm ba nhánh song song, chịu trách nhiệm xử lý các luồng dữ liệu dị đồng nhất:

- Nhánh Đặc trưng Động (Dynamic Branch):** Xử lý luồng dữ liệu chuỗi thời gian (vận tốc, gia tốc, tỷ lệ trễ) thông qua cấu trúc **LSTM 2 lớp (với `hidden_dim=64`)**. Cấu trúc này giúp trích xuất quán tính giao thông và bắt sóng xung kích khi vận tốc thay đổi.
- Nhánh Ngữ cảnh Phân loại (Categorical Branch):** Thay vì sử dụng One-hot encoding gây hiện tượng bùng nổ số chiều và ma trận thưa, đồ án áp dụng **Tầng Nhúng không gian (Embedding Layers với `dim=8`)**. Kỹ thuật này ánh xạ các định danh rời rạc (ID đoạn đường, mã Phường/Xã) thành các vector dày đặc liên tục, giúp mạng nơ-ron học được tính tương đồng về không gian giữa các khu vực địa lý lân cận.
- Nhánh Đặc trưng Tĩnh (Static Branch):** Sử dụng mạng nơ-ron truyền thẳng (Feed-Forward Neural Network - FNN) để xử lý các thuộc tính vật lý bất biến (tọa độ GPS, số làn xe, chiều dài đoạn đường).

Đầu ra của ba nhánh này được kết hợp (concatenate) tạo thành một vector đại diện toàn cục (Fusion Vector) trước khi đi qua các tầng phân loại cuối cùng (Classifier).

Sơ đồ kiến trúc mạng Fusion (Context-Aware Hybrid Architecture)



* Ghi chú: Mô hình kết hợp đặc trưng động (chuỗi thời gian) và đặc trưng tĩnh (ngữ cảnh không gian) để dự báo.

Hình 5.4: Sơ đồ kiến trúc tổng thể

b. Cơ chế Học chuyển giao và Khởi động ấm (SL-to-RL Warmstart)

Một nhược điểm chí mạng của Học tăng cường (RL) là vấn đề "Khởi động lạnh" (Cold Start). Nếu khởi tạo trọng số ngẫu nhiên, Agent sẽ mất lượng lớn thời gian để mò mẫm các quy luật vật lý cơ bản, dễ dẫn đến mất hội tụ.

Để giải quyết, đề án áp dụng chiến lược **Warmstart**: Mạng Fusion đa nhánh ban đầu được tiền huấn luyện (Pre-train) hoàn toàn bằng phương pháp Học có giám sát (SL) với hàm mất mát Cross-Entropy. Sau khi mạng đã có "bản năng" nhận diện giao thông cơ bản, **toàn bộ trọng số (weights) này được chuyển giao (Transfer) và nạp trực tiếp vào Đặc vụ DQN** trước khi bắt đầu quá trình tinh chỉnh (Fine-tuning) bằng RL. Điều này giúp Agent có một xuất phát điểm cực kỳ vững chắc.


c. Tối ưu hóa với Double DQN và Hàm Phần thưởng Không đối xứng (Asymmetric Reward Shaping)

Đặc vụ (Agent) sử dụng thuật toán **Double DQN** kết hợp bộ nhớ kinh nghiệm (Replay Buffer) dung lượng \$100.000\$ mẫu. Việc sử dụng mạng mục tiêu (Target Network) tách biệt với mạng chính sách (Policy Network) giúp triệt tiêu hội chứng ảo tưởng sức mạnh (Overestimation Bias) vốn thường gặp ở Q-Learning truyền thống.

Tuy nhiên, **"trái tim" và bí quyết thành công của hệ thống nằm ở thiết kế Hàm phần thưởng (Reward Shaping)**. Nhằm triệt tiêu thiên kiến lớp đa số (mô hình thích đoán kẹt xe thành thông thoáng để an toàn), đề án thiết kế một cơ chế điểm phạt phi tuyến tính và không đối xứng:

- **Thưởng khích lệ:** Nếu dự báo chính xác mức độ kẹt xe, Agent nhận \$+2\$ điểm.
- **Phạt cảnh cáo:** Nếu dự báo sai lệch nhẹ (chênh lệch 1 mức, ví dụ thực tế Mức 2 nhưng đoán Mức 1), Agent bị trừ \$-1\$ điểm. Đây là mức sai số có thể chấp nhận được trong thực tế.
- **Phạt sinh tử (Fatal Penalty):** Nếu hệ thống đối mặt với thảm họa (Thực tế là Mức 4 hoặc 5) nhưng Agent báo cáo sai thành thông thoáng (Mức 0 hoặc 1), mức phạt sẽ tăng vọt lên từ **\$-10\$ đến \$-20\$ điểm**.

Cơ chế "đòn bẩy" này tạo ra một rào cản tâm lý, ép Agent phải nhạy bén tối đa với các tín hiệu thảm họa, chấp nhận hy sinh một phần nhỏ độ chính xác ở các lớp thông thoáng để bảo vệ năng lực cảnh báo sớm cho người dùng.



Hình 5.5: Đồ thị hàm phần thưởng

d. Đánh giá ưu điểm và thách thức

- **Ưu điểm vượt trội:** Kiến trúc lai đạt được cả hai mục tiêu cực hạn: Tốc độ hội tụ nhanh (nhờ tri thức tiền huấn luyện từ Warmstart) và năng lực thu hồi (Recall) xuất sắc tại các lớp kẹt xe nặng (nhờ Hàm thưởng không đối xứng ép buộc Agent chú ý vào các trường hợp ngoại lai).
- **Thách thức:** Quá trình tinh chỉnh các siêu tham số của hàm thưởng (tỷ lệ phạt giữa -10 và -20) đòi hỏi phải thử nghiệm (trial-and-error) liên tục để tránh việc Agent rơi vào thái cực ngược lại là chứng "hoang tưởng" (luôn dự báo kẹt xe). Ngoài ra, cấu trúc Double DQN tiêu tốn bộ nhớ và thời gian tính toán cao hơn so với mô hình giám sát thuần túy.

5.2. Kỹ thuật Thiết kế Đặc trưng (Feature Engineering & Justification)

Dữ liệu thô thu thập từ mạng lưới cảm biến giao thông thường chứa nhiều độ trễ, nhiễu và các điểm khuyết thiếu (missing values). Do đó, để mô hình học máy – đặc biệt là mạng nơ-ron chuỗi thời gian – có thể hội tụ và trích xuất quy luật hiệu quả, dữ liệu thô cần được biến đổi thành các vector đặc trưng mang ý nghĩa vật lý. Mục này trình bày các kỹ thuật nền tảng để cấu trúc hóa không gian trạng thái từ dòng dữ liệu thô.

5.2.1. Cấu trúc Cửa sổ trượt (Sliding Window) và Đảm bảo tính liên tục (Continuity)

Bài toán dự báo giao thông không xem xét từng điểm dữ liệu đơn lẻ mà đánh giá chuỗi diễn biến trong quá khứ để suy luận tương lai. Để định dạng dữ liệu cho mô hình chuỗi thời gian (như LSTM), hệ thống sử dụng kỹ thuật **Cửa sổ trượt (Sliding Window)**.

a. Thông số và Biện luận kích thước cửa sổ (Window Size Justification)

Hệ thống thiết lập kích thước cửa sổ $W = 12$ bước thời gian (time-steps). Với tần suất thu thập dữ liệu (Aggregation resolution) là 15 phút/bước, kích thước cửa sổ này tương đương với **3 giờ đồng hồ** lịch sử.

Cơ sở lựa chọn: Việc chọn 3 giờ không phải là ngẫu nhiên mà dựa trên đặc tính lan truyền của dòng xe. Kẹt xe đô thị không xảy ra tức thời mà phát triển theo dạng "sóng xung kích" (Shockwaves). Một khoảng thời gian 3 giờ là vừa đủ để mô hình quan sát trọn vẹn một chu kỳ chuyển dịch trạng thái: từ giai đoạn giao thông bắt đầu ùn ứ tích lũy, đạt đỉnh điểm vỡ trận (bottleneck), cho đến khi dòng xe bắt đầu giải phóng.

- Nếu chọn cửa sổ quá ngắn (ví dụ 30 phút), mô hình sẽ thiếu "tầm nhìn" dài hạn để nhận biết xu hướng.
- Nếu chọn quá dài (ví dụ 6 giờ), dữ liệu sẽ chứa nhiều thông tin nhiễu từ các khung giờ không liên quan, làm giảm hiệu suất tính toán của bộ nhớ hệ thống.

Cửa sổ này sẽ trích xuất một chuỗi đầu vào $X = [x_{t-11}, x_{t-10}, \dots, x_t]$ để dự báo nhãn mục tiêu $Y = y_{t+1}$ (dự báo trước 15 phút).


b. Thuật toán kiểm soát tính liên tục (Continuity Check Algorithm)

Một thách thức lớn của dữ liệu IoT (Internet of Things) ngoài thực tế là hiện tượng rớt mạng, mất tín hiệu cảm biến, dẫn đến các "lỗ hổng" thời gian trong cơ sở dữ liệu. Nếu hệ thống áp dụng cửa sổ trượt một cách mù quáng, cửa sổ có thể chứa những dòng dữ liệu đứt gãy (ví dụ: nhảy vọt từ 08:00 sáng thẳng đến 14:00 chiều do mất kết nối). Việc đưa một chuỗi đứt gãy không gian thời gian vào mô hình LSTM sẽ gây ra sự sai lệch nghiêm trọng về mặt nhận thức động lực học.

Để khắc phục, đồ án thiết kế thuật toán **Kiểm tra tính liên tục (find_valid_window_starts)**. Thuật toán này hoạt động như một màng lọc nghiêm ngặt:

1. Quét qua trục thời gian và kiểm tra khoảng cách (delta) giữa mọi điểm dữ liệu liên tiếp trong cửa sổ $W+1$ (bao gồm cả điểm mục tiêu).
2. Chỉ những cửa sổ thỏa mãn điều kiện khoảng cách thời gian giữa các bước *chính xác tuyệt đối* bằng 15 phút (không chứa giá trị NaN hoặc bước nhảy vọt) mới được gán cờ hợp lệ (Valid).
3. Các cửa sổ vi phạm sẽ bị loại bỏ hoàn toàn nhằm bảo vệ tính toàn vẹn (Data Integrity) của tập huấn luyện. Kỹ thuật này đóng vai trò then chốt giúp Agent Học tăng cường không bị học sai các quy luật vật lý nhân quả.

Cơ chế Cửa sổ trượt (Sliding Window) và Thuật toán kiểm tra tính liên tục



* Nguyên tắc: Mô hình chỉ học từ các chuỗi thời gian liên tục. Mọi cửa sổ chứa dữ liệu rác/thiếu sẽ bị hệ thống tự động loại bỏ.

Hình 5.6: Sơ đồ minh họa cơ chế Cửa sổ trượt và Thuật toán kiểm tra tính liên tục

5.2.2. Nhúng bối cảnh không gian (Spatial & Categorical Embedding)

Trong mạng lưới giao thông thực tế, các đặc trưng mang tính định danh không gian như Mã đoạn đường (**segment_id**) hay Mã khu vực (**ward_id**) đóng vai trò là "bối cảnh" cực kỳ quan trọng. Cùng một mức vận tốc 20 km/h, nhưng tại một con hẻm nhỏ thì đó là trạng thái lưu thông bình thường, trong khi tại một đại lộ lớn thì đó là dấu hiệu của ùn tắc nghiêm trọng. Để mô hình hiểu được bối cảnh này, các biến phân loại (categorical variables) cần được chuyển đổi thành biểu diễn toán học.

a. Hạn chế của One-hot Encoding và "Lời nguyền số chiều"

Phương pháp truyền thống thường được sử dụng cho dữ liệu phân loại là One-hot Encoding. Tuy nhiên, khi áp dụng vào bài toán mạng lưới giao thông diện rộng, phương pháp này bộc lộ hai lỗi hỏng chí mạng:

- Lời nguyền số chiều (Curse of Dimensionality):** Nếu mạng lưới có 500 đoạn đường, One-hot Encoding sẽ tạo ra một vector có 500 chiều cho mỗi điểm dữ liệu, trong đó chỉ có một giá trị \$1\$ và \$499\$ giá trị \$0\$. Điều này tạo ra một "ma trận thưa" (Sparse Matrix) khổng lồ, làm cạn kiệt bộ nhớ RAM, gây ra hiện tượng tiêu biến đạo hàm (Vanishing Gradient) và làm chậm tốc độ hội tụ của thuật toán DQN một cách nghiêm trọng.
- Sự trực giao vô nghĩa về mặt không gian:** Về mặt toán học, One-hot Encoding giả định tất cả các đoạn đường đều hoàn toàn độc lập và trực giao với nhau. Khoảng cách (Euclidean hoặc Cosine) giữa đoạn đường A và đoạn đường B luôn bằng với khoảng cách từ A đến C. Điều này vi phạm hoàn toàn quy luật vật lý giao thông, nơi các đoạn đường lân cận hoặc cùng tính chất sẽ có sự tương quan chặt chẽ với nhau.

b. Kỹ thuật Nhúng (Embedding Layer) và Chiều không gian

Để giải quyết triệt để vấn đề trên, đồ án tích hợp **Tầng Nhúng (Embedding Layer)** vào mạng nơ-ron để xử lý các ID không gian. Kỹ thuật này ánh xạ một tập hợp rời rạc, phân tán

thành một không gian vector đặc (Dense Vector Space) có số chiều thấp và mang tính liên tục.

Hệ thống thiết lập siêu tham số kích thước không gian nhúng là **Embedding Dimension = 8**. Kích thước 8 chiều được lựa chọn thông qua thực nghiệm (Empirical tuning) vì nó đóng vai trò là "Điểm vàng" (Sweet spot):

- Đủ lớn để mô hình có dung lượng đại diện (representational capacity) nhằm mã hóa các đặc tính hình học phức tạp của đoạn đường.
- Đủ nhỏ để không làm bùng nổ số lượng tham số huấn luyện, tránh hiện tượng học vẹt (Overfitting) trên dữ liệu nhiễu.

c. Tác dụng: Mô hình hóa "Khoảng cách Giao thông"


Sức mạnh lớn nhất của tầng Embedding nằm ở khả năng tự học (Self-learning). Ban đầu, các vector 8 chiều được khởi tạo ngẫu nhiên. Trải qua hàng ngàn vòng lặp huấn luyện lan truyền ngược (Backpropagation), trọng số của các vector này liên tục được tinh chỉnh để tối ưu hóa hàm mất mát (Loss function) dự báo kẹt xe.

Kết quả là, mô hình tự động xây dựng được một "Bản đồ nhận thức" về **Khoảng cách giao thông (Traffic Distance)** thay vì khoảng cách địa lý đơn thuần. Trong không gian 8 chiều này:

- Các đoạn đường tuy cách xa nhau về mặt địa lý nhưng có cùng chức năng giao thông (ví dụ: cùng là nút giao thông thường xuyên xảy ra xung đột rẽ trái, hoặc cùng là đường nhánh nối ra xa lộ) sẽ có các vector nhúng "hội tụ" về gần nhau.
- Các đoạn đường lân cận nằm trên cùng một trục hành lang giao thông (Corridor) sẽ chia sẻ các cụm vector tương đồng, giúp Agent nội suy được trạng thái ùn tắc lan truyền từ đoạn đường này sang đoạn đường khác một cách tự nhiên.

Nhờ kỹ thuật này, hệ thống dự báo không chỉ nhìn thấy dữ liệu dưới dạng những con số rời rạc, mà thực sự "hiểu" được cấu trúc địa hình học và động lực học ẩn của toàn mạng lưới đường bộ.

So sánh One-hot Encoding vs. Dense Embedding



Hình 5.7: So sánh One-hot Encoding vs Dense Embedding

5.2.3. Mã hóa tính chu kỳ thời gian (Cyclical Temporal Encoding)

Lưu lượng và tình trạng giao thông đô thị mang tính chu kỳ (Seasonality) cực kỳ rõ rệt, lặp đi lặp lại theo nhịp sinh học của con người (như chu kỳ ngày đêm, chu kỳ tuần làm việc). Do đó, "Thời gian trong ngày" (Time of day) là một trong những đặc trưng quan trọng nhất để dự báo kẹt xe. Tuy nhiên, cách biểu diễn dữ liệu thời gian thô vào mô hình học máy quyết định trực tiếp đến tốc độ và khả năng hội tụ của hệ thống.

a. Hạn chế của mã hóa tuyến tính (Linear / Ordinal Encoding)

Cách tiếp cận thông thường và ngây thơ (naive approach) là biểu diễn thời gian (Giờ) dưới dạng số nguyên tuyến tính từ \$0\$ đến \$23\$. Dưới góc độ tối ưu hóa của mạng nơ-ron, cách mã hóa này tạo ra một **khoảng cách giả tạo (Artificial Distance)** cực kỳ nguy hiểm.

- Về mặt toán học, khoảng cách giữa \$23\$ (23:00 đêm) và \$0\$ (00:00 sáng hôm sau) là $\Delta = |23 - 0| = 23$.
- Về mặt vật lý giao thông, 23:59 và 00:01 là hai thời điểm liền kề nhau, trạng thái giao thông gần như không thay đổi.

Sự đứt gãy tuyến tính này (bước nhảy đột ngột từ 23 về 0) tạo ra một bề mặt dốc gồ ghề (Loss landscape discontinuities) trong không gian đặc trưng. Thuật toán Gradient Descent sẽ phải tốn rất nhiều chu kỳ (epochs) chỉ để học cách "bề cong" logic toán học nhằm bù đắp cho sự vô lý này, làm giảm hiệu suất của mô hình.

b. Kỹ thuật Mã hóa Chu kỳ bằng hàm Lượng giác (Sin/Cos Transformation)

Để giải quyết triệt để sự đứt gãy, đồ án áp dụng kỹ thuật **Mã hóa Chu kỳ (Cyclical Temporal Encoding)**. Kỹ thuật này chiếu trục thời gian tuyến tính 1 chiều lên một đường tròn đơn vị 2 chiều, thông qua hai hàm lượng giác hình sin và cô-sin.

Với t là thời điểm hiện tại (tính bằng phút hoặc giờ) và T là tổng chu kỳ (ví dụ $T = 24$ đối với giờ, $T = 60$ đối với phút), đặc trưng thời gian được tách thành hai vector liên tục:

$$\text{Time_Sin} = \sin\left(\frac{2\pi}{T} \cdot t\right)$$

$$\text{Time_Cos} = \cos\left(\frac{2\pi}{T} \cdot t\right)$$

Lý do phải sử dụng đồng thời cả Sin và Cos: Nếu chỉ dùng hàm Sin, các thời điểm đối xứng qua trục tung (ví dụ 06:00 sáng và 18:00 chiều) sẽ cho ra cùng một giá trị, gây ra sự nhầm lẫn (Collision) cho Agent. Việc kết hợp cả hai hàm tạo ra một tọa độ (x, y) duy nhất trên đường tròn cho mỗi phút trong ngày.

c. Lợi ích tối ưu hóa cho mô hình chuỗi thời gian

Kỹ thuật này mang lại những ưu điểm vượt trội cho các cấu trúc mạng như LSTM hay Double DQN:

1. **Bảo toàn khoảng cách vật lý:** Trong không gian không gian 2D mới, khoảng cách Euclidean giữa 23:59 và 00:01 tiệm cận về \$0\$, phản ánh chính xác sự liên tục của dòng chảy thời gian thực tế.
2. **Làm mịn không gian đặc trưng (Feature space smoothing):** Việc loại bỏ các điểm gãy (discontinuities) giúp bề mặt hàm mất mát (Loss Function) trở nên trơn tru hơn.

Mạng nơ-ron nhận được độ dốc (gradients) ổn định, từ đó tăng tốc độ hội tụ và giảm thiểu khả năng rơi vào cực tiểu cục bộ (Local Minima) trong quá trình huấn luyện RL.

5.2.4. Chuẩn hóa và Tiền xử lý (Scaling & Imputation)

Trong kiến trúc của các hệ thống Học máy hiện đại, quá trình tiền xử lý không chỉ đơn thuần là bước làm sạch dữ liệu, mà là một trụ cột của quy trình MLOps nhằm đảm bảo tính ổn định toán học khi huấn luyện và tính nhất quán khi triển khai thực tế. Đồ án áp dụng một pipeline (đường ống) tiền xử lý nghiêm ngặt bao gồm các kỹ thuật sau:

a. Xử lý khuyết thiếu cục bộ (Local Imputation)

Trong thực tiễn thu thập dữ liệu từ hệ thống cảm biến IoT giao thông, hiện tượng mất gói tin tạm thời (drop-out) diễn ra thường xuyên. Khác với các đứt gãy kéo dài (đã được xử lý bằng cách loại bỏ toàn bộ cửa sổ tại Mục 5.2.1), các khuyết thiếu cục bộ (chỉ mất tín hiệu trong 1-2 chu kỳ tương đương 15-30 phút) được giữ lại để tránh lãng phí dữ liệu.

Hệ thống áp dụng kỹ thuật **Điền khuyết tiến (Forward Fill - ffill)** để xử lý các lỗ hổng này. Cơ sở khoa học của phương pháp này dựa trên **định luật quán tính vật lý của dòng xe**: trong một khoảng thời gian cực ngắn, trạng thái động lực học của giao thông (vận tốc, mật độ) có xu hướng duy trì tính kế thừa từ thời điểm ngay trước đó. Việc lấy giá trị của x_{t-1} lấp vào x_t mang lại độ tin cậy cao hơn so với việc nội suy trung bình (mean imputation), đồng thời không phá vỡ tính nhân quả (causality) của chuỗi thời gian.

b. Cơ sở toán học của Chuẩn hóa đặc trưng (Feature Scaling)

Dữ liệu giao thông đa phương thức chứa các đặc trưng có sự chênh lệch khổng lồ về mặt độ lớn (Magnitude):

- Đặc trưng tuần hoàn (Time Sin/Cos): Bị giới hạn nghiêm ngặt trong đoạn $[-1, 1]$.
- Vận tốc (Speed): Dao động trong khoảng $[0, 80]$ km/h.
- Độ trễ thời gian (Delay): Có thể bùng nổ lên tới hàng ngàn giây (> 3000 s).

Nếu đưa trực tiếp không gian đặc trưng thô này vào các mạng nơ-ron như LSTM, hệ thống sẽ rơi vào tình trạng **"Mù Nơ-ron" (Neuron Blindness)**. Khi đó, trọng số (weights) của các biến có độ lớn cao như Delay sẽ thống trị hoàn toàn luồng Gradient truyền ngược, trong khi các tín hiệu quan trọng nhưng có độ lớn nhỏ (như Time Sin/Cos) bị triệt tiêu hoàn toàn. Về mặt hình học tối ưu, sự chênh lệch này biến bề mặt hàm mất mát (Loss Landscape) thành một "khe núi" hẹp và sâu. Thuật toán Gradient Descent sẽ phải dao động (oscillation) liên tục theo đường zigzag tốn kém, dẫn đến hội tụ cực kỳ chậm hoặc mắc kẹt tại cực tiểu cục bộ.

Để giải quyết, đồ án áp dụng bộ biến đổi **StandardScaler**, chuẩn hóa các biến liên tục về phân phối chuẩn (với kỳ vọng $\mu = 0$ và độ lệch chuẩn $\sigma = 1$):

$$x_{\text{scaled}} = \frac{x - \mu}{\sigma}$$

Phép biến đổi này nắn chỉnh bề mặt hàm mất mát thành dạng **lòng chảo đẳng hướng (Isotropic Bowl)**, cho phép vector Gradient hướng thẳng trực tiếp đến điểm cực tiểu toàn cục (Global Minimum), tối ưu hóa tốc độ học của Agent DQN.

c. Nguyên tắc cách ly chống Rò rỉ dữ liệu (Preventing Data Leakage)

Một trong những sai lầm nghiêm trọng làm suy giảm tính minh bạch của các nghiên cứu AI là hiện tượng rò rỉ dữ liệu (Data Leakage) ở bước chuẩn hóa. Nếu tính toán μ và σ trên toàn bộ tập dữ liệu trước khi phân chia, mô hình sẽ ngầm "nhìn trộm" thông tin phân phối của tương lai, dẫn đến kết quả đánh giá (F1-score, Accuracy) cao một cách ảo tưởng, nhưng lại thất bại thảm hại khi triển khai thực tế.

Để tuân thủ tiêu chuẩn khoa học, đồ án thiết lập quy trình cách ly tuyệt đối:

- Hàm `fit()` chỉ được thực thi duy nhất trên tập Huấn luyện (Training set) để trích xuất các tham số thống kê của "quá khứ".
- Các tham số μ , σ này lập tức được "đóng băng".
- Hàm `transform()` sử dụng các tham số đã đóng băng để biến đổi tập Kiểm định (Validation set) và tập Kiểm thử (Test set), đảm bảo mô hình đối mặt với dữ liệu kiểm thử hoàn toàn như một thực thể chưa từng quan sát.

d. Đóng gói "Bản hợp đồng Dữ liệu" (Preprocessing Artifacts)

Trong kiến trúc phần mềm thực tế, mô hình AI không hoạt động cô lập mà phải giao tiếp với các hệ thống ứng dụng phía người dùng. Để giải quyết bài toán chênh lệch môi trường (Environment Drift), toàn bộ bộ biến đổi (bao gồm `StandardScaler` và các `LabelEncoder` của nhánh Categorical) được hệ thống đóng gói thành một tệp nhị phân duy nhất mang tên `preprocessing_artifacts.pkl`.

Tệp này hoạt động như một **"Bản hợp đồng Dữ liệu" (Data Contract)**. Khi hệ thống được triển khai lên Server (Deploy), mọi yêu cầu dự báo (Inference Request) gọi từ Ứng dụng di động truyền về đều bắt buộc phải đi qua tệp Artifacts này để chuẩn hóa. Cơ chế này đảm bảo luồng dữ liệu thời gian thực (Real-time data) từ API luôn được chiếu (project) vào đúng hệ quy chiếu không gian mà mô hình đã được huấn luyện, duy trì tính nhất quán tuyệt đối (Consistency) từ phòng thí nghiệm ra đến môi trường Production.

5.2.5. Quy trình Đánh giá và Tuyển chọn Đặc trưng (Feature Quality Assessment)

Trong thiết kế không gian trạng thái (State Space) cho mô hình Deep Learning và mạng Đặc vụ (RL Agent), việc "nhồi nhét" quá nhiều đặc trưng đầu vào không những không làm tăng hiệu suất mà còn dẫn đến hiện tượng "Lời nguyền số chiều" (Curse of Dimensionality). Càng nhiều chiều dữ liệu, không gian tìm kiếm càng phình to, tỷ lệ nhiễu (noise) tăng cao và bộ nhớ Replay Buffer sẽ nhanh chóng bị vắt kiệt.

Do đó, trước khi chốt danh sách đặc trưng cuối cùng đưa vào huấn luyện, đồ án thiết lập một quy trình tuyển chọn hai bước vô cùng nghiêm ngặt:

a. Bước 1 - Phân tích và Khử Đa cộng tuyến (Multicollinearity Removal)

Đa cộng tuyến là hiện tượng hai hoặc nhiều đặc trưng đầu vào có mối tương quan tuyến tính quá mạnh với nhau. Ví dụ: Nếu hệ thống đã có đặc trưng `speed_ratio` (tỷ lệ vận tốc hiện tại so với vận tốc tự do) thì việc giữ lại biến `avg_speed` (vận tốc trung bình thô) là một sự dư thừa thông tin (Redundant features).

Sự tồn tại của các biến dư thừa này sẽ khiến ma trận hiệp phương sai bị suy biến, làm cho trọng số của mạng Nơ-ron trở nên bất ổn định (instability) – một thay đổi nhỏ của dữ liệu đầu vào cũng làm Gradient nhảy vọt.

Để giải quyết, đồ án xây dựng **Ma trận tương quan Pearson/Spearman** phân tích chéo toàn bộ các biến. Hệ thống áp dụng một ngưỡng cắt cứng (Hard Threshold) là 0.7. Bất kỳ cặp đặc trưng nào có hệ số tương quan tuyệt đối $|r| > 0.7$, hệ thống sẽ tự động đối chiếu với biến Mục tiêu (Target Label) và chỉ giữ lại biến nào có sức mạnh dự báo độc lập cao hơn, biến còn lại bị loại bỏ hoàn toàn khỏi pipeline.

(Ghi chú chèn ảnh: Tại đây trình bày [Hình 5.q: Ma trận tương quan Heatmap], khoanh vùng các cặp đặc trưng bị loại bỏ do vi phạm ngưỡng đa cộng tuyến).

b. Bước 2 - Xếp hạng Tầm quan trọng Đặc trưng (Feature Importance Ranking)

Sau khi loại bỏ các biến dư thừa, những biến còn lại tiếp tục phải trải qua bài kiểm tra "Sức mạnh dự báo". Vì bản chất của giao thông là sự tương tác phi tuyến (ví dụ: mưa to + giờ cao điểm = kẹt xe worse), các phương pháp kiểm định thống kê tuyến tính thông thường (như Anova) sẽ không thể đánh giá đúng vai trò của từng biến.


Đồ án sử dụng thuật toán **Random Forest (Rừng ngẫu nhiên)** kết hợp với kỹ thuật kiểm chứng chéo **Stratified K-Fold** để xếp hạng đặc trưng.

- **Lý do dùng Random Forest:** Thuật toán này có khả năng tự động tính toán chỉ số **Gini Importance** (hoặc Mean Decrease Impurity) bằng cách đo lường mức độ giảm nhiễu thông tin (Entropy) mỗi khi một đặc trưng được chọn để phân nhánh cây quyết định.
- **Lý do dùng Stratified K-Fold:** Vì phân phối nhãn kẹt xe đang mất cân bằng cực hạn (Thảm họa lớp 5 chỉ chiếm $< 1\%$), kỹ thuật Stratified (Phân tầng) đảm bảo rằng trong bất kỳ tập kiểm chứng nào, tỷ lệ các ca thảm họa vẫn được duy trì. Điều này ép thuật toán Random Forest phải đánh giá tầm quan trọng của đặc trưng dựa trên khả năng phát hiện thảm họa, chứ không chỉ dựa trên nhóm đa số.

Kết quả của bước này là một danh sách được xếp hạng (Ranked List). Các đặc trưng mang tín hiệu khuếch đại mạnh như `traffic_index` (Chỉ số ùn tắc), `speed_delta` (Gia tốc giảm), và `is_peak_hour` (Giờ cao điểm) thường đứng đầu. Các đặc trưng nằm ở nhóm "đuôi dài" (đuôi nhiễu, điểm Gini tiệm cận 0%) sẽ bị cắt bỏ để tối ưu hóa không gian nhúng của Agent.

(Ghi chú chèn ảnh: Tại đây trình bày [Hình 5.p: Biểu đồ xếp hạng Feature Importance], thể hiện sự chênh lệch tầm quan trọng giữa nhóm tín hiệu cốt lõi và nhóm nhiễu).

Sơ đồ luồng dữ liệu MLOps và vai trò của Bản hợp đồng dữ liệu (Artifacts)



Hình 5.8: Sơ đồ luồng dữ liệu MLOps

5.2.5. Quy trình Đánh giá và Tuyển chọn Đặc trưng (Feature Quality Assessment)

Trong thiết kế không gian trạng thái (State Space) cho mô hình Deep Learning và mạng Đặc vụ (RL Agent), việc kiểm soát chất lượng đặc trưng đầu vào là yếu tố quyết định tốc độ hội tụ và khả năng tổng quát hóa của hệ thống. Đồ án thiết lập một quy trình đánh giá hai bước dựa trên thực chứng dữ liệu: Khử đa cộng tuyến và Xếp hạng tầm quan trọng.


a. Bước 1 - Phân tích và Khử Đa cộng tuyến (Multicollinearity Removal)

Đa cộng tuyến là hiện tượng hai hoặc nhiều đặc trưng đầu vào có mối tương quan tuyến tính quá mạnh, dẫn đến sự dư thừa thông tin (Redundant features). Sự tồn tại của chúng làm suy biến ma trận hiệp phương sai, khiến trọng số của mạng Nơ-ron trở nên bất ổn định.

Dựa trên kết quả thực nghiệm từ **Ma trận tương quan (Hình 5.q)**, hệ thống đã phát hiện các cặp biến vi phạm nghiêm trọng giả định độc lập:

- **Cặp avg_speed và speed_ratio:** Đạt hệ số tương quan dương cực đại $r = 0.97$. Điều này hoàn toàn hợp lý về mặt toán học vì tỷ lệ vận tốc được tính trực tiếp từ vận tốc trung bình. Việc giữ cả hai sẽ gây ra lỗi đa cộng tuyến hoàn hảo (Perfect Multicollinearity).
- **Cặp traffic_index và avg_speed:** Có độ tương quan âm rất mạnh $r = -0.89$. Khi vận tốc giảm sâu, chỉ số kẹt xe sẽ tăng vọt.

Quyết định thiết kế: Thay vì giữ toàn bộ, hệ thống áp dụng ngưỡng cắt tương quan $|r| > 0.85$. Đối với cặp (avg_speed, speed_ratio), đồ án quyết định chỉ giữ lại một đại diện có sức mạnh phân nhánh tốt hơn (được kiểm chứng ở Bước 2) để tối ưu hóa số chiều cho không gian vector đầu vào, giảm tải cho bộ nhớ Replay Buffer của Agent DQN.



Hình 5.9: Ma trận Tương quan (Heatmap) thể hiện hiện tượng đa cộng tuyến giữa các đặc trưng giao thông


b. Bước 2 - Xếp hạng Tầm quan trọng Đặc trưng (Feature Importance Ranking)

Sau khi nhận diện các mối tương quan, đồ án sử dụng thuật toán **Random Forest** để đánh giá "Sức mạnh dự báo" thực tế của từng đặc trưng đối với biến mục tiêu (Target Label). Khác với tương quan tuyến tính, Random Forest đo lường bằng chỉ số **Gini Importance** (Mức độ giảm nhiễu thông tin khi phân nhánh cây quyết định), giúp đánh giá chính xác các tác động phi tuyến tính.

Kết quả trích xuất từ **Biểu đồ Xếp hạng Đặc trưng (Hình 5.p)** cho thấy sự phân hóa cực kỳ rõ nét thành 3 nhóm tín hiệu:

- Nhóm Tín hiệu Cốt lõi (Core Signals):** Đóng vai trò thống trị tuyệt đối trong việc phát hiện kẹt xe. Dẫn đầu là **traffic_index** với mức đóng góp áp đảo $\sim 40\%$, tiếp theo là **delay_seconds** ($\sim 25\%$) và **avg_speed** ($\sim 12\%$). Nhóm này phản ánh trực tiếp động lực học của "sóng xung kích" giao thông. Đây cũng là lý do ở Bước 1, biến **avg_speed** chứng minh được giá trị giữ lại cao hơn **speed_ratio** (chỉ đạt $\sim 5\%$).
- Nhóm Bối cảnh Động (Contextual Signals):** Bao gồm **is_rush_hour** (Giờ cao điểm), **weather_condition_id** (Thời tiết), và tính chu kỳ **time_sin**, **time_cos**. Dù chỉ đóng góp mức nhỏ ($2\% - 4\%$ mỗi biến), nhưng đây là các biến "công tắc" cực kỳ quan trọng. Mạng Nơ-ron kết hợp chúng với nhóm cốt lõi để nhận diện các vụ kẹt xe thảm họa do mưa bão hoặc tan tã.
- Nhóm Vùng Nhiễu/Tĩnh (Static Noise):**
Các thuộc tính vật lý tĩnh như **lanes** (Số làn xe) và **road_length** (Chiều dài đoạn đường) nằm ở vị trí chót bảng với mức đóng góp $< 1\%$. Vì chúng không biến thiên theo thời gian, thuật toán cây quyết định không thể dùng chúng để rẽ nhánh cảnh báo. Tuy nhiên, thay vì loại bỏ hoàn toàn, hệ thống đã khôn khéo đẩy các ID định danh không gian này vào **Tầng Nhúng (Embedding Layer)** (như đã trình bày ở Mục 5.2.2) để học bối cảnh chìm, thay vì dùng làm chuỗi tín hiệu thời gian trực tiếp.

Quy trình chất lọc khắt khe này giúp Agent DQN của đề án "nhẹ gánh" tính toán, tập trung toàn bộ tài nguyên mạng Nơ-ron vào những tín hiệu mang tính quyết định sinh tử của bài toán.



Hình 5.10: Xếp hạng mức độ đóng góp của các đặc trưng dựa trên Gini Importance (Random Forest)

5.3. Chiến lược Cân bằng Dữ liệu (Resampling Comparative Analysis)

Dữ liệu chất lượng cao là nền tảng cốt lõi định đoạt sự thành bại của mọi mô hình Học máy. Tuy nhiên, đối với bài toán giao thông không gian - thời gian, việc sở hữu một bộ dữ liệu lớn không đồng nghĩa với việc sở hữu một bộ dữ liệu tốt. Mục này trình bày các thách thức về mặt phân phối dữ liệu và biện luận cho chiến lược "Cân bằng Lai" (Hybrid Resampling) mà đề án đã thiết kế.

5.3.1. Thách thức từ dữ liệu mất cân bằng cực hạn (Extreme Imbalance)

a. Bản chất vật lý của sự mất cân bằng

Trong các hệ thống AI ứng dụng vào thế giới thực, sự phân phối của dữ liệu hiếm khi đạt trạng thái đồng đều lý tưởng. Thống kê từ tập dữ liệu lịch sử thu thập trên mạng lưới giao thông cho thấy một hiện tượng **Mất cân bằng cực hạn (Extreme Imbalance)**. Cụ thể, các trạng thái lưu thông từ Thông thoáng đến Ổn định (Lớp 0, 1, 2) chiếm tỷ trọng áp đảo lên tới hơn 90%. Ngược lại, các sự kiện ùn tắc nghiêm trọng (Lớp 4) và "Vỡ trận/Kẹt cứng" (Lớp 5) là những điểm dị thường (Anomalies), chỉ chiếm tỷ lệ vô cùng nhỏ nhoi, chưa tới 0.1% trên tổng dung lượng dữ liệu.

Sự chênh lệch này không phải là lỗi hệ thống cảm biến, mà là phản ánh chính xác quy luật vật lý và hành vi xã hội: Giao thông đô thị phần lớn thời gian trong ngày duy trì ở trạng thái dòng tự do (free-flow) và chỉ sụp đổ cấu trúc vào một số khung giờ cao điểm hoặc khi có sự cố bất ngờ.

b. Bẫy "Nghịch lý độ chính xác" và Thiên kiến lớp đa số (Majority Class Bias)

Dù hợp lý về mặt vật lý, sự mất cân bằng cực hạn này lại là một "bản án tử" đối với thuật toán tối ưu hóa của mạng nơ-ron nếu được đưa trực tiếp vào huấn luyện.

Khi sử dụng dữ liệu thô, mô hình sẽ đối mặt với **Nghịch lý độ chính xác (Accuracy Paradox)**. Nếu một mạng Nơ-ron học cách gian lận bằng việc *luôn luôn* dự báo là "Thông thoáng" (Lớp 1) bất chấp dữ liệu đầu vào là gì, nó nghiêm nhiên đạt độ chính xác (Accuracy) tổng thể trên 90%. Thuật toán Gradient Descent sẽ ghi nhận đây là một chiến lược "thành công" để giảm thiểu hàm mất mát (Loss function) nhanh nhất. Hệ quả là, mô hình bị rơi vào bẫy **Thiên kiến lớp đa số (Majority Class Bias)**, trở nên hoàn toàn "mù màu" và phớt lờ các tín hiệu của lớp thảm họa (Recall của Lớp 4, 5 tiệm cận 0%).


c. Tác động tiêu cực đến Đặc vụ Học tăng cường (DQN Agent)

Đối với mạng Double DQN được thiết kế trong đề án, sự mất cân bằng này còn gây ra hậu quả tàn khốc hơn ở khâu lấy mẫu kinh nghiệm (Experience Replay).

Bộ nhớ Replay Buffer lưu trữ các quá trình chuyển trạng thái (transitions). Nếu nạp dữ liệu thô, 99% không gian trong Buffer sẽ chứa các mẫu kinh nghiệm nhằm chần chừ của Lớp 0 và 1. Khi Agent bốc ngẫu nhiên một mẻ dữ liệu (Batch) để huấn luyện, xác suất bốc trúng một kinh nghiệm về "sự cố kẹt xe Lớp 5" là cực kỳ thấp. Thiếu đi sự "cọ xát" với các trạng thái nguy hiểm, Agent sẽ hình thành một chính sách (Policy) lười biếng, phản ứng chậm trễ và không thể kích hoạt kịp thời cảnh báo khi kẹt xe thực sự bắt đầu lan rộng.

Do đó, việc tái định hình lại không gian phân phối dữ liệu (Resampling) trước khi đưa vào huấn luyện không chỉ là một thủ thuật tiền xử lý, mà là một yêu cầu sinh tử để mô hình có thể phát hiện thảm họa.

```
🕒 Đang thực hiện cân bằng dữ liệu (quá trình này mất khoảng 10-15 phút do sử dụng CTGAN)...  
  
🚀 CTGAN Augmenting Class 5: 259 seeds -> 22000 windows  
/usr/local/lib/python3.9/site-packages/sdv/single_table/base.py:79: UserWarning: We strongly recommend you to use the CTGAN Augmenting Class 5: 259 seeds -> 22000 windows  
warnings.warn(  
🚀 CTGAN Augmenting Class 4: 2367 seeds -> 30000 windows  
/usr/local/lib/python3.9/site-packages/sdv/single_table/base.py:79: UserWarning: We strongly recommend you to use the CTGAN Augmenting Class 4: 2367 seeds -> 30000 windows  
warnings.warn(  
🚢 Stage 2 Smart-Filtering: Analyzing 2117695 windows...  
🌸 Hybrid-Filtering Class 0: 652873 -> 205464  
🌸 Hybrid-Filtering Class 1: 953849 -> 250000  
🌸 Hybrid-Filtering Class 2: 456981 -> 205464  
  
✅ Hoàn thành trong 11.25 phút!  
📁 Kích thước tập dữ liệu: (9935822, 23)  
💾 Đã lưu tại: /workspace/ai-core/data/processed/02_balanced_training_data.parquet
```



Hình 5.11: So sánh Phân phối dữ liệu Gốc và Phân phối Vàng sau khi áp dụng Cân bằng Lại

5.3.2. Phân tích điểm yếu của phương pháp nội suy tuyến tính (SMOTE/ADASYN)

Trong các bài toán Học máy truyền thống, để giải quyết vấn đề mất cân bằng dữ liệu, các kỹ thuật sinh mẫu nhân tạo như **SMOTE** (Synthetic Minority Over-sampling Technique) hoặc **ADASYN** thường là lựa chọn mặc định. Tuy nhiên, trong bối cảnh đồ án này, các phương pháp trên đã bị loại bỏ hoàn toàn khỏi kiến trúc hệ thống sau quá trình đánh giá rủi ro thuật toán.

a. Cơ chế nội suy tuyến tính và sự vi phạm Động lực học Giao thông

Bản chất cốt lõi của SMOTE và ADASYN là tạo ra dữ liệu mới bằng phép **Nội suy tuyến tính (Linear Interpolation)**. Thuật toán sẽ chọn ngẫu nhiên một mẫu thiểu số, tìm k láng giềng gần nhất của nó (k -Nearest Neighbors) trong không gian đặc trưng n -chiều, và vẽ các đường thẳng nối giữa chúng để tạo ra các điểm dữ liệu ảo nằm dọc trên các đoạn thẳng đó.

Tuy nhiên, giao thông đô thị là một hệ thống vật lý phức tạp. Động lực học dòng xe (Traffic Flow Dynamics) bị chi phối bởi các **ràng buộc phi tuyến nghiêm ngặt** (Ví dụ: Mối quan hệ giữa Vận tốc - Mật độ - Lưu lượng thường được mô tả bằng các đường cong bậc hai

parabol theo mô hình Greenshields, không phải đường thẳng). Việc SMOTE thực hiện nội suy một cách mù quáng (blind interpolation) cắt ngang qua không gian trạng thái phi tuyến này sẽ phá vỡ hoàn toàn các định luật vật lý cơ bản.

b. Hiện tượng "Trạng thái Ảo giác Phi vật lý" (Unphysical Hallucinations)

Hậu quả trực tiếp của việc dùng SMOTE là sự xuất hiện của các điểm dữ liệu nằm ngoài "quỹ đạo vật lý" cho phép.

Ví dụ minh họa: Giả sử có hai mẫu kẹt xe thực tế: Điểm \$A\$ (Vận tốc rất thấp, đang mưa to) và Điểm \$B\$ (Vận tốc trung bình, trời tạnh ráo nhưng ngay sát ngã tư). Khi SMOTE nội suy tuyến tính giữa \$A\$ và \$B\$, nó có thể vô tình sinh ra điểm \$C\$ mang đặc tính lai tạp: **Mật độ xe đang kẹt cứng (đặc tính của A), nhưng vận tốc dòng xe lại vọt lên 60 km/h (đặc trưng của đường vắng).**


Trạng thái \$C\$ này không bao giờ có thể tồn tại trong thực tế. Đồ án định nghĩa đây là các **"Trạng thái Ảo giác Phi vật lý" (Unphysical Hallucinated States)**.

c. Hậu quả trí mạng đối với Đặc vụ Học tăng cường (DQN Agent)

Đối với một mô hình phân lớp thống kê đơn giản, vài điểm dữ liệu ảo giác có thể chỉ làm giảm nhẹ độ chính xác (Accuracy). Nhưng đối với mạng **Double DQN** – một thuật toán dựa trên việc khám phá và học luật nhân - quả từ môi trường (Markov Decision Process), hậu quả là sự sụp đổ toàn hệ thống.

Nếu các "trạng thái ảo giác" này bị tiêm vào tập dữ liệu, chúng sẽ trực tiếp đầu độc bộ nhớ kinh nghiệm (Replay Buffer). Agent sẽ học được những quy luật logic sai lệch (ví dụ: tin rằng có thể tăng tốc thoát khỏi đám kẹt xe khi mật độ đang là 100%). Hậu quả là Hàm giá trị (Q-value) bị tính toán sai, dẫn đến việc Agent đưa ra các quyết định điều hướng hoang tưởng khi được triển khai vào môi trường thực tế.

Chính vì rủi ro "đầu độc" không gian trạng thái này, đồ án bác bỏ việc sử dụng các công cụ sinh mẫu tuyến tính truyền thống và đề xuất giải pháp mạnh mẽ hơn bằng Mô hình sinh tạo sâu (Deep Generative AI).



Hình 5.12: Sự vi phạm ràng buộc phi tuyến của phương pháp nội suy SMOTE

5.3.3. Chiến lược Cân bằng Lai (Hybrid Resampling: Anchor-based & Sequence-CTGAN)

Để giải quyết triệt để rủi ro "ảo giác phi vật lý" của phương pháp nội suy tuyến tính, đồng thời khắc phục sự mất cân bằng cực hạn của dữ liệu, đề án đề xuất và tự phát triển một chiến lược **Cân bằng Lai (Hybrid Resampling)**. Chiến lược này là sự kết hợp tinh tế giữa nghệ thuật cắt tỉa dữ liệu có kiểm soát và mô hình Trí tuệ nhân tạo tạo sinh (Generative AI), được chia làm hai nhánh xử lý song song.

a. Nhánh 1: Cắt tỉa thông minh dựa trên Mỏ neo (Smart Under-sampling with Anchor-based Filtering)

Đối với nhóm dữ liệu đa số (Lớp 0, 1, 2) chiếm tới hàng trăm ngàn mẫu, việc giữ lại toàn bộ sẽ làm cạn kiệt tài nguyên tính toán và gây ra "Thiên kiến lớp đa số" (Majority Class Bias). Tuy nhiên, nếu cắt giảm ngẫu nhiên (Random Under-sampling) một cách bạo lực, hệ thống sẽ đánh mất các đặc trưng phân phối thực tế của dòng tự do.

Giải pháp được áp dụng là cơ chế "**Lọc dựa trên Mỏ neo**" (Anchor-based Filtering).

- Hệ thống lựa chọn **Lớp 3 (Kẹt xe trung bình)** làm điểm mỏ neo (Anchor) do lớp này mang tín hiệu chuyển tiếp quan trọng và có số lượng mẫu tự nhiên ở mức vừa đủ (khoảng \$51,000\$ cửa sổ).

- Dựa trên mỏ neo này, thuật toán tiến hành cắt tỉa có chọn lọc các Lớp 0, 1, và 2 xuống một ngưỡng trần (Threshold) dao động từ \$200000\$ đến 250000\$ của sổ.

Cơ chế này đạt được mục tiêu kép: Vừa triệt tiêu khối lượng dữ liệu dư thừa (Noise reduction) giúp tăng tốc độ hội tụ của Agent DQN, vừa bảo vệ nghiêm ngặt **Tính thứ bậc tự nhiên (Ordinal Hierarchy)** của giao thông (Số lượng mẫu Lớp 1 > Lớp 0 > Lớp 2 > Lớp 3), giúp mạng Nơ-ron không bị mất phương hướng khi nhận diện bối cảnh bình thường.

b. Nhánh 2: Bơm máu thảm họa với Sequence-CTGAN (Over-sampling)

Đối với nhóm thiểu số nghiêm trọng (Lớp 4 và Lớp 5), thay vì nội suy các đường thẳng vô nghĩa, đề án ứng dụng **Mạng đối nghịch sinh tạo có điều kiện dạng bảng (Conditional Tabular GAN - CTGAN)**. Đây là một kiến trúc Deep Learning tiên tiến, bao gồm một mạng Sinh (Generator) và mạng Phân biệt (Discriminator) cạnh tranh với nhau để học được phân phối xác suất chung (Joint Distribution) đa chiều của dữ liệu thực.

Kết quả của quá trình huấn luyện đối nghịch này là hệ thống đã tổng hợp thêm thành công \$30,000\$ của sổ cho Lớp 4 và \$22,000\$ của sổ cho Lớp 5. Các điểm dữ liệu sinh ra không phải là bản sao chép, mà là các "kịch bản thảm họa" hoàn toàn mới nhưng tuân thủ tuyệt đối các ràng buộc vật lý phi tuyến của mạng lưới giao thông.


c. Chìa khóa thành công: Đảm bảo Tính nhất quán Chuỗi thời gian (Temporal Consistency)

Điểm đột phá kỹ thuật đáng tự hào nhất của đề án nằm ở cách cấu hình CTGAN. Về bản chất nguyên thủy, CTGAN được thiết kế để sinh ra các dòng dữ liệu độc lập (Single-row Tabular Data). Nếu áp dụng một cách ngây thơ vào bài toán này, nó sẽ sinh ra các timestep rời rạc, làm vỡ vụn chuỗi thời gian, khiến mạng LSTM (ở Mục 5.1.3) hoàn toàn vô dụng.

Để vượt qua rào cản này, hệ thống đã tái định dạng không gian sinh tạo: **Ép CTGAN phải sinh dữ liệu theo đơn vị Khối (Window-level Generation)**.

Mỗi mẫu dữ liệu mà CTGAN học và sinh ra không phải là một trạng thái tại thời điểm \$t\$, mà là một **ma trận của sổ trượt gồm 13 bước thời gian liên tiếp** (12 bước đầu vào + 1 bước nhãn mục tiêu). Sự điều chỉnh kiến trúc này buộc mạng Discriminator phải đánh giá sự hợp lý của toàn bộ diễn biến "sóng xung kích". Nhờ đó, dữ liệu nhân tạo được sinh ra giữ nguyên **Tính nhất quán Chuỗi thời gian (Temporal Consistency)** – vận tốc sẽ giảm dần có tính toán, độ trễ sẽ tích lũy theo từng phút, tái hiện chân thực quá trình một vụ ùn tắc giao thông dần dần lan rộng thành thảm họa vỡ trận.

Kiến trúc Chiến lược Cân bằng Lai (Anchor-based & Sequence-CTGAN)



Hình 5.13: Kiến trúc Chiến lược Cân bằng lai

5.3.4. Màn lọc Hậu kiểm Vật lý (Physical Sanity Check)

Mặc dù Sequence-CTGAN sở hữu năng lực học phân phối xác suất đa chiều xuất sắc, bản chất cốt lõi của mạng GAN vẫn là một mô hình tối ưu hóa thống kê (Statistical Model), không phải là một cỗ máy mô phỏng vật lý (Physics Engine). Do đó, trong quá trình hội tụ đối nghịch, mạng Generator thỉnh thoảng vẫn vấp phải các nhiễu cục bộ, sinh ra những cửa sổ dữ liệu tuy khớp về mặt toán học nhưng lại phi lý về mặt thực tế.

Để bảo vệ tuyệt đối tính toàn vẹn (Data Integrity) của tập huấn luyện trước khi nạp vào bộ nhớ Replay Buffer của Agent DQN, đồ án thiết lập một chốt chặn cuối cùng mang tên: **Màn lọc Hậu kiểm Vật lý (Physical Sanity Filter)**. Màn lọc này hoạt động dựa trên hai định luật cốt lõi của động lực học dòng xe:

a. Ràng buộc tỷ lệ nghịch Tốc độ - Mật độ (Speed-Density Constraint)

Theo lý thuyết vĩ mô của giao thông (Điển hình là mô hình Greenshields), mật độ phương tiện và vận tốc dòng xe luôn tồn tại một mối quan hệ tỷ lệ nghịch khắt khe.

Hệ thống thiết lập một rào chắn logic (Logic Gate) quét qua từng bước thời gian của dữ liệu CTGAN sinh ra, đối chiếu cặp giá trị **traffic_index** (đại diện cho độ kẹt xe/mật độ) và **current_speed_kmh** (vận tốc).

- Nếu hệ thống phát hiện một điểm dữ liệu có **traffic_index** ở mức cao (ví dụ $\$ > 8.0\$$, tức kẹt cứng) nhưng **current_speed_kmh** lại lọt vào ngưỡng dòng tự do ($\$ > 40\$$ km/h), điểm dữ liệu này lập tức bị dán nhãn "Ảo giác GAN" (GAN Hallucination) và toàn bộ cửa sổ chứa nó bị loại bỏ. Màn lọc này triệt tiêu hoàn toàn các trạng thái không gian phi vật lý.

b. Tính mượt mà thời gian và Giới hạn gia tốc (Temporal Smoothness)

Giao thông là một hệ động lực có quán tính lớn (High Inertia). Sự sụp đổ trạng thái từ thông thoáng (Lớp 0) sang vỡ trận (Lớp 5) là sự lan truyền của một sóng xung kích (Shockwave) cần thời gian tích lũy, không thể xảy ra dưới dạng "dịch chuyển tức thời".


Hệ thống tính toán đạo hàm bậc nhất của vận tốc theo thời gian ($\Delta v / \Delta t$) để đo lường gia tốc của dòng xe giữa các bước liên kề (15\$ phút/bước).

- Hệ thống đặt ra một "Ngưỡng thay đổi đột biến" (Sudden Jump Threshold). Nếu CTGAN sinh ra một chuỗi mà vận tốc rớt thẳng đứng từ 60\$ km/h xuống 5\$ km/h chỉ trong vòng một bước thời gian (15\$ phút) mà không hề có tín hiệu sự cố cực đoan (như tai nạn nghiêm trọng), cửa sổ đó sẽ bị đánh giá là gây cấu trúc (Sequence Artifact) và bị từ chối. Kỹ thuật này ép dữ liệu nhân tạo phải duy trì tính mượt mà thời gian (Temporal Smoothness).

Kết luận:

Thông qua hai màng lọc tĩnh (Không gian) và động (Thời gian) này, tập dữ liệu thẩm họa tổng hợp từ CTGAN được "thanh lọc" một cách triệt để. Kết quả thu được là một **"Tập dữ liệu Vàng" (Gold Standard Dataset)**. Tập dữ liệu này không chỉ cân bằng hoàn hảo về mặt tỷ lệ các lớp, mà còn tuân thủ sự thật vật lý 100%, tạo tiền đề vững chắc cho giai đoạn huấn luyện các mạng Nơ-ron cốt lõi ở phần tiếp theo.

Cơ chế hoạt động của Màng lọc Hậu kiểm Vật lý (Physical Sanity Filter) trên dữ liệu CTGAN



Hình 5.14: Cơ chế hoạt động của Màng lọc Hậu kiểm Vật lý

5.4. Trạng tiền huấn luyện Giám sát (Supervised Baseline Justification)

Trước khi tiến hành khai thác sức mạnh của thuật toán Học tăng cường sâu (Deep Reinforcement Learning), việc chuẩn bị một điểm xuất phát vững chắc cho Đặc vụ (Agent) là yếu tố quyết định tốc độ và độ ổn định của toàn bộ hệ thống. Mục này trình bày quy trình xây dựng "Bản năng cơ sở" cho mô hình thông qua phương pháp Học có giám sát (Supervised Learning).

5.4.1. Xây dựng "Trực giác" ban đầu cho Agent thông qua Học có giám sát (Supervised Pre-training)

a. Triết lý thiết kế: Khắc phục hội chứng "Khởi động lạnh" (Cold-start Problem)

Trong kiến trúc Học tăng cường thuần túy, mạng Nơ-ron thường khởi tạo các trọng số (weights) một cách ngẫu nhiên. Khi áp dụng vào bài toán giao thông, điều này đồng nghĩa với việc Agent sẽ bắt đầu ở trạng thái "hoàn toàn mù mờ" về các định luật vật lý cơ bản. Agent sẽ phải tốn hàng ngàn chu kỳ (episodes) thực hiện các hành động ngẫu nhiên, vấp phải vô số sai lầm hiển nhiên chỉ để lờ mờ nhận ra rằng "vận tốc giảm thì kẹt xe tăng". Quá trình thám hiểm (Exploration) mù quáng này rất dễ đẩy mạng Nơ-ron rơi vào các điểm cực tiểu cục bộ (Local Minima) và không bao giờ hội tụ.

Để phá vỡ rào cản này, đồ án thiết lập một pha **Tiền huấn luyện Giám sát (Supervised Pre-training)**. Triết lý ở đây là tạo ra một "Người thầy" (Supervised Model) để truyền đạt **trực giác vật lý ban đầu** cho Agent. Mạng Nơ-ron sẽ được dạy cách phân lớp 6 mức độ giao thông trên Tập dữ liệu Vàng (Balanced Data) đã được chất lọc từ Mục 5.3, biến bài toán dự báo thành một bài toán Phân lớp đa biến (Multi-class Classification).


b. Tính đồng nhất về Kiến trúc (Architectural Consistency)

Để tri thức có thể được chuyển giao (Transfer) một cách trọn vẹn, kiến trúc của mô hình tiền huấn luyện được thiết kế **đồng nhất tuyệt đối** với mạng Q-Network của Agent DQN (bao gồm các luồng LSTM xử lý chuỗi thời gian, các tầng Embedding mã hóa không gian và các tầng Fully Connected). Việc sử dụng chung một khuôn mẫu kiến trúc đảm bảo rằng mọi ma trận trọng số (Weight Matrices) và độ lệch (Biases) học được trong pha Giám sát có thể được nạp trực tiếp (Inject) vào Agent RL ở giai đoạn sau mà không gặp bất kỳ xung đột nào về chiều dữ liệu.

c. Tối ưu hóa hàm mất mát với Focal Loss và Trọng số Phạt (Class Weights)

Ngay cả khi tập dữ liệu đã được cân bằng, ranh giới vật lý giữa các mức độ giao thông (đặc biệt là giữa Thông thoáng - Lớp 0 và Ổn định - Lớp 1) thường rất mờ nhạt, khiến thuật toán Gradient Descent dễ bị bối rối. Để ép mô hình phải tập trung trí lực vào các thảm họa thực sự, đồ án đã áp dụng một tổ hợp tối ưu hóa hàm mất mát cực kỳ sắc bén:

1. **Focal Loss:** Thay vì sử dụng Cross-Entropy truyền thống vốn đối xử bình đẳng với mọi mẫu, Focal Loss thêm vào một tham số điều biến (Modulating factor) γ . Cơ chế này chủ động hạ thấp trọng số của các mẫu "dễ đoán" (ví dụ: đường vắng lúc 2h sáng), ép mạng Nơ-ron dồn toàn bộ đạo hàm (Gradients) để học các mẫu "khó đoán" và mang tính ranh giới.
2. **Ma trận Trọng số Nhãn (Class Weights):** Hệ thống được cấu hình để phân bổ mức phạt (Penalty) tỷ lệ nghịch với độ an toàn của trạng thái. Phân bổ thực nghiệm cho thấy các lớp an toàn (0, 1, 2) chỉ nhận trọng số phạt nhẹ (\$0.8\$), trong khi các lớp thảm họa (4 và 5) phải chịu trọng số phạt cực nặng (lên tới \$1.8\$). Cấu trúc phạt phi đối xứng này đóng vai trò như một "màng lọc chú ý", cảnh cáo mạng Nơ-ron rằng việc dự báo sai một vụ kẹt xe vỡ trận sẽ phải trả giá đắt hơn rất nhiều so với việc nhầm lẫn giữa hai trạng thái thông thoáng.




Hình 5.15: Cơ chế điều hướng sự chú ý của Focal Loss so với Cross-Entropy

d. Đánh giá Hiệu suất Tiền huấn luyện (Pre-training Performance)

Quá trình huấn luyện mô hình giám sát cơ sở (Baseline) được điều hướng bởi thuật toán giảm tốc độ học tự động (Learning Rate Scheduler) và cơ chế Dừng sớm (Early Stopping) để chống học vẹt (Overfitting).

Kết quả thực nghiệm ghi nhận mô hình đạt đỉnh hội tụ ở chỉ số **Macro-F1 xấp xỉ 0.7**. Mặc dù con số \$0.70\$ có vẻ khiêm tốn nếu so với các bài toán phân lớp hình ảnh tĩnh, nhưng trong lĩnh vực dự báo chuỗi thời gian giao thông mang tính hỗn loạn cao, đây là một điểm số xuất sắc. Điểm nhấn thực sự không nằm ở độ chính xác tổng thể, mà nằm ở năng lực **Thu hồi (Recall)**: Mô hình đã phát triển một "khứu giác" nhạy bén, khả năng bắt trúng các thảm họa Lớp 4 và Lớp 5 đạt mức tiệm cận \$83\% - 84\%\$.

Bộ trọng số đỉnh cao này (lưu tại [best_traffic_model_manual_h15.pt](#)) chính thức hoàn thành nhiệm vụ xây dựng trực giác ban đầu. Nó đã sẵn sàng để được cấy ghép vào "não bộ" của Agent Học tăng cường, mở ra giai đoạn huấn luyện tối ưu hóa quyết định dài hạn ở phần tiếp theo.



Hình 5.16: Đánh giá hiệu suất Phân lớp của Mô hình Baseline

5.4.2. Giải pháp khắc phục vấn đề "Khởi động lạnh" (Cold Start) trong Học tăng cường

Mặc dù thuật toán Học tăng cường (Reinforcement Learning - RL) có khả năng tối ưu hóa các chiến lược dài hạn xuất sắc thông qua cơ chế Thử và Sai (Trial and Error), nó lại vấp phải một rào cản vật lý nghiêm trọng trong giai đoạn đầu huấn luyện, được gọi là **Hội chứng Khởi động lạnh (Cold Start Problem)**. Đồ án giải quyết bài toán này thông qua chiến lược Học chuyển giao (Transfer Learning).

a. Thách thức từ sự thám hiểm ngẫu nhiên (Random Exploration Dilemma) Trong một quy trình RL tiêu chuẩn, mạng Q-Network ban đầu được khởi tạo với các trọng số hoàn toàn ngẫu nhiên (Random Initialization). Do Agent chưa có bất kỳ khái niệm nào về bối cảnh không gian hay động lực học dòng xe, bước vào giai đoạn thám hiểm (Exploration), nó sẽ đưa ra hàng ngàn quyết định vô nghĩa và phi vật lý. *Ví dụ điển hình:* Agent có thể quan sát trạng thái môi trường đang ở mức vận tốc 80 km/h, đường vắng, nhưng lại xuất ra dự báo là "Kẹt xe vỡ trận" (Mức 5).

Hậu quả của sự mù mờ này là vô cùng tàn khốc:

- Đầu độc bộ nhớ:** Bộ nhớ kinh nghiệm (Replay Buffer) nhanh chóng bị lấp đầy bởi các bước chuyển trạng thái (transitions) rác, không mang lại giá trị học tập.
- Lãng phí tài nguyên:** Hệ thống phải đốt cháy một lượng khổng lồ tài nguyên tính toán (GPU/CPU) qua hàng vạn chu kỳ (episodes) chỉ để Agent lờ mờ nhận ra những quy luật vật lý cơ bản nhất mà một con người mất vài giây để hiểu.

b. Cơ chế "Tiêm tri thức" (Knowledge Injection & Weight Transfer) Để khắc phục rủi ro này, đồ án từ bỏ phương pháp khởi tạo ngẫu nhiên truyền thống và áp dụng cơ chế **"Khởi**

động ấm" (Warm-start) bằng cách "tiêm" trực tiếp tri thức từ Trạm tiền huấn luyện giám sát (Mục 5.4.1) vào mạng nơ-ron của Agent.

Quá trình tiêm tri thức diễn ra như sau:

- Mạng Nơ-ron tiền huấn luyện (Supervised Baseline) sau khi đạt đỉnh hội tụ (với Macro-F1 ~ 0.70) đã hình thành được một "bản đồ trực giác" về giao thông. Nó biết chắc chắn rằng vận tốc cao đi kèm độ trễ thấp thì không thể nào là kẹt xe.
- Toàn bộ ma trận trọng số (Weight Matrices) và hệ số chệch (Biases) của mạng này được trích xuất và sao chép chính xác (1:1) vào cả hai mạng của kiến trúc Double DQN: **Policy Network** (Mạng quyết định) và **Target Network** (Mạng mục tiêu).
- Nhờ thao tác này, Agent DQN bỏ qua hoàn toàn giai đoạn "trẻ sơ sinh" mò mẫm vô hướng. Ngay tại chu kỳ (episode) đầu tiên, Agent đã có năng lực nhận diện bối cảnh sắc bén của một chuyên gia giám sát, và chỉ dùng sức mạnh của RL để tinh chỉnh (fine-tune) lại quyết định nhằm tối ưu hóa Hàm phần thưởng không đối xứng (Mục 5.1.3).

c. Đóng gói và Đồng bộ hóa Hệ sinh thái (MLOps Artifacts Synchronization) Tuy nhiên, việc truyền trọng số mạng nơ-ron sẽ trở nên hoàn toàn vô dụng nếu dữ liệu đầu vào không được đồng bộ. Một mạng Nơ-ron được huấn luyện trên dữ liệu đã qua chuẩn hóa (Scaled Data) sẽ trả về kết quả rác nếu Agent RL bón cho nó dữ liệu thô (Raw Data) hoặc dữ liệu chuẩn hóa bằng một tỷ lệ khác.

Để đảm bảo tính toàn vẹn, đồ án đóng gói toàn bộ hệ sinh thái tri thức thành các tệp **Artifacts**:

1. Tệp **best_traffic_model_baseline.pt**: Chứa tri thức toán học (Trọng số Nơ-ron).
2. Tệp **preprocessing_artifacts.pkl**: Chứa hệ quy chiếu vật lý (Scaler, Label Encoders).

Khi Agent khởi động môi trường Gymnasium (RL Environment), nó bắt buộc phải tải cả hai tệp này lên. Mọi trạng thái giao thông (State) từ môi trường trước khi đưa vào Agent đều phải đi qua **Scaler** để biến đổi, sau đó mới được xử lý bởi mạng nơ-ron đã chứa sẵn trọng số **.pt**. Cơ chế này tạo ra một pipeline kín kẽ, triệt tiêu mọi khả năng rò rỉ hoặc sai lệch dữ liệu, đảm bảo Agent phát huy 100% công lực ngay từ giây phút khởi chạy đầu tiên.

5.4.3. Chuyển giao trọng số và Khởi động ấm (Warm-start Weight Injection)

Sự khác biệt cốt lõi giữa Học có giám sát (SL) và Học tăng cường (RL) nằm ở mục tiêu tối ưu. Mô hình SL tối ưu hóa dự báo dựa trên một nhãn có sẵn (Cross-Entropy Loss), trong khi Đặc vụ RL tối ưu hóa chuỗi hành động để đạt được tổng phần thưởng lớn nhất (Tối ưu hóa phương trình Bellman). Việc kết nối hai mục tiêu này đòi hỏi một cơ chế tiêm tri thức khéo léo để không làm phá vỡ cấu trúc mạng Nơ-ron.

a. Cơ chế thực thi kỹ thuật (State-Dict Injection) Trong các bài toán RL kinh điển, mạng Q-Network thường được khởi tạo bằng các hàm sinh ngẫu nhiên (như Xavier hoặc He


Initialization). Tuy nhiên, đối với hệ thống dự báo giao thông trong đề án, phương pháp này bị loại bỏ hoàn toàn.

Khi Môi trường RL (Gymnasium) và Agent Double DQN được khởi tạo, hệ thống tiến hành một thủ thuật can thiệp sâu vào cấu trúc PyTorch:

1. **Khóa đồng nhất kiến trúc:** Mạng Q-Network (bao gồm cả Policy Net và Target Net) được định nghĩa với kiến trúc giống hệt mạng phân lớp đa nhánh (LSTM + Embedding + FNN) đã trình bày ở Mục 5.1.3.
2. **Load State Dict:** Hệ thống gọi trực tiếp từ điển trạng thái (State Dictionary) từ tệp `best_traffic_model_manual_h15.pt` thu được ở Mục 5.4.1. Toàn bộ ma trận trọng số (Weight Matrices) và hệ số chệch (Biases) tại từng lớp Neuron được trích xuất và ánh xạ tỷ lệ 1:1 sang mạng Q-Network.

b. Lợi ích thực chứng: Rút ngắn tiến trình Thám hiểm (Exploration Bypass) Việc "Khởi động ấm" (Warm-start) bằng trọng số đã qua huấn luyện mang lại hai lợi ích thực chứng mang tính bước ngoặt cho hệ thống:

- **Vượt qua Giai đoạn Thám hiểm mù quáng (Blind Exploration):** Thay vì mò mẫm vô định và thực hiện hàng ngàn hành động sai lệch gây lãng phí tài nguyên, Agent ngay từ Epoch đầu tiên đã mang trong mình năng lực của một chuyên gia phân tích dữ liệu. Nó ngay lập tức nhận diện và phân loại chính xác các trạng thái giao thông cơ bản.
- **Chuyển dịch Trọng tâm Tối ưu hóa:** Nhờ có sẵn trực giác vật lý, Agent không cần phải tốn công học lại quy luật "vận tốc thấp thì kẹt xe". Nó dành toàn bộ sức mạnh tính toán và khả năng nội suy của mạng Neuron để tập trung giải quyết bài toán phức tạp hơn: **Tối ưu hóa chiến lược hành động nhằm tối đa hóa Phần thưởng (Reward)**. Cụ thể, Agent sẽ học cách tinh chỉnh lại các trọng số ở những điểm ranh giới để né tránh các mức phạt sinh tử (Fatal Penalty) khi bỏ lọt thảm họa Lốp 5, từ đó thiết lập một chính sách (Policy) cảnh báo sớm an toàn và nhạy bén hơn rất nhiều so với mô hình SL thuần túy.



Hình 5.17: Lợi ích thực chứng của Chuyển giao Trọng số lên tốc độ hội tụ Phần thưởng

5.5. Kiến trúc Đặc vụ Học tăng cường (Double DQN Architecture)

Sau khi được tiêm "bản năng" từ Trạm tiền huấn luyện (Mục 5.4), Đặc vụ (Agent) chính thức bước vào Môi trường Học tăng cường (Gymnasium Environment). Tại đây, bài toán dự báo kẹt xe được định hình lại thành một quá trình Ra quyết định Markov (Markov Decision Process - MDP).

5.5.1. Lựa chọn thuật toán Double DQN (DDQN)

Trong hệ sinh thái các thuật toán Học tăng cường Sâu (Deep Reinforcement Learning), việc lựa chọn thuật toán phải tuân thủ nghiêm ngặt đặc tính của Không gian hành động (Action Space). Vì hệ thống cần phân loại trạng thái giao thông thành 6 mức độ rời rạc (Discrete classes từ 0 đến 5), các thuật toán dựa trên hàm giá trị (Value-based methods) tỏ ra ưu việt hơn so với các phương pháp tối ưu chính sách liên tục (như PPO hay SAC).

Tuy nhiên, thay vì sử dụng mạng Q-Learning sâu truyền thống (Standard DQN), đề án quyết định triển khai kiến trúc **Double Deep Q-Network (DDQN)**. Quyết định này xuất phát từ việc khắc phục một lỗi hỏng toán học chí mạng:

a. Lỗi hỏng của DQN truyền thống: Hội chứng Đánh giá vượt mức (Overestimation Bias)

Trong thuật toán DQN tiêu chuẩn, hàm mục tiêu để cập nhật mạng Nơ-ron (phương trình Bellman) được định nghĩa như sau:

$$Y_t^{DQN} = R_{t+1} + \gamma \max_a Q(S_{t+1}, a; \theta_t)$$

Vấn đề cốt lõi nằm ở toán tử cực đại hóa $\max$. DQN sử dụng cùng một bộ trọng số mạng θ_t để thực hiện đồng thời hai nhiệm vụ: (1) Lựa chọn hành động tốt nhất và (2) Đánh giá giá trị (Q-value) của hành động đó.

Do môi trường giao thông chứa lượng lớn nhiễu ngẫu nhiên, các ước lượng Q-value ban đầu thường không chính xác. Việc liên tục lấy giá trị cực đại $\max$ sẽ khiến các sai số dương (positive noise) bị tích lũy qua từng vòng lặp. Hậu quả là Agent rơi vào trạng thái **"Ảo tưởng giá trị" (Overestimation Bias)**: Nó đánh giá quá cao phần thưởng của một số hành động nhất định (ví dụ: luôn nghĩ rằng dự báo "Thông thoáng" sẽ mang lại điểm cao bất chấp thực tế), dẫn đến chính sách hội tụ sai lệch và thất bại trong việc phát hiện thảm họa.

b. Giải pháp của Double DQN: Tách biệt quyền lực (Decoupling Selection and Evaluation)

Để triệt tiêu hội chứng ảo tưởng này, kiến trúc DDQN phân tách quá trình tính toán thành hai mạng Nơ-ron độc lập, chia sẻ cùng cấu trúc nhưng khác biệt về trọng số:

- Mạng Chính (Policy Network - θ):** Đóng vai trò là "Người ra quyết định". Nó phân tích trạng thái tiếp theo S_{t+1} và tìm ra hành động a^* có Q-value cao nhất.
- Mạng Đích (Target Network - θ^-):** Đóng vai trò là "Ban giám khảo". Nó tiếp nhận hành động a^* do Mạng Chính đề xuất, và đưa ra đánh giá khách quan về giá trị Q thực sự của hành động đó.


Phương trình cập nhật của DDQN được viết lại thành:

$$Y_t^{DDQN} = R_{t+1} + \gamma Q(S_{t+1}, \arg\max_a Q(S_{t+1}, a; \theta_t); \theta^-_t)$$

c. Tác dụng đối với hệ thống dự báo giao thông

Sự "tách biệt quyền lực" này hoạt động như một cơ chế kiểm chứng chéo (Cross-validation). Nếu Mạng Chính bị nhiễu và đề xuất một dự báo sai lệch (như bỏ lọt kẹt xe Mức 5), Mạng Đích (với bộ trọng số được cập nhật chậm hơn và ổn định hơn) sẽ đánh giá lại hành động đó, trả về một Q-value thấp, từ đó dập tắt sự ảo tưởng của Agent. Kỹ thuật này giúp đường cong Loss ổn định hơn, và đặc biệt quan trọng trong việc giữ cho Agent duy trì sự cảnh giác cao độ trước các tín hiệu thảm họa giao thông.

Kiến trúc Double DQN - Cơ chế kiểm chứng chéo chống ảo tưởng giá trị (Overestimation Bias)



Hình 5.18: Kiến trúc Double DQN - Cơ chế kiểm chứng chéo

5.5.2. Cấu trúc mạng Q-Network và Siêu tham số Huấn luyện

Để thuật toán Double DQN có thể giải quyết được bài toán không gian - thời gian phức tạp, việc thiết kế "thể xác" (cấu trúc mạng nơ-ron) và tinh chỉnh các "hệ số vận hành" (siêu tham số) đòi hỏi sự tính toán kỹ lưỡng về mặt thực nghiệm.

a. Kiến trúc Q-Network Đa phương thức (Multi-modal Architecture)

Đặc vụ sử dụng một mạng Nơ-ron sâu (DNN) làm hàm xấp xỉ giá trị (Value Function Approximator). Để tối ưu hóa quy trình Khởi động ấm (Warm-start) đã trình bày ở Mục 5.4, kiến trúc của mạng Q-Network được thiết kế kế thừa và đồng nhất hoàn toàn với mô hình Baseline.

Mạng sử dụng cấu trúc **Đa nhánh (Multi-branch)** để xử lý các luồng dữ liệu dị đồng nhất từ môi trường giao thông (Gymnasium Environment):

- **Nhánh Dynamic:** Sử dụng các khối LSTM để trích xuất quán tính và sự biến thiên của chuỗi thời gian (vận tốc, độ trễ).
- **Nhánh Categorical:** Sử dụng tầng Embedding để giải mã mã ngữ cảnh không gian (ID đoạn đường, Phường/Xã).
- **Nhánh Static:** Dùng mạng FNN xử lý các đặc tính hình học không đổi của mạng lưới.

Toàn bộ các đặc trưng này hội tụ về các tầng Fully Connected (FC) cuối cùng. Thay vì xuất ra xác suất của các nhãn (như mô hình phân lớp), lớp output của mạng Q-Network xuất ra một vector chứa \$6\$ giá trị Q (Q-values), tương ứng với \$6\$ mức độ kẹt xe.

b. Tối ưu hóa xấp xỉ giá trị với Huber Loss (Smooth L1 Loss)

Trong các bài toán hồi quy (Regression) hoặc xấp xỉ hàm giá trị của RL, Mean Squared Error (MSE) thường là hàm mất mát mặc định. Tuy nhiên, đồ án đã loại bỏ MSE và quyết định sử dụng **Huber Loss (Smooth L1 Loss)**. Quyết định này xuất phát từ bản chất vật lý của dữ liệu cảm biến giao thông.

Dữ liệu thu thập từ các trạm quan trắc IoT thường xuyên xuất hiện các điểm dị thường (Outliers) như tín hiệu GPS nhảy vọt, hoặc nhiễu cục bộ.

- **Điểm yếu của MSE:** Hàm MSE bình phương sai số (x^2). Nếu có một giá trị nhiễu lớn xuất hiện trong batch huấn luyện, MSE sẽ khuếch đại sai số này lên theo cấp số nhân, tạo ra một gradient khổng lồ làm "nổ" trọng số mạng (Exploding Gradient), khiến Agent quên sạch những gì đã học.
- **Sự ưu việt của Huber Loss:** Huber Loss hoạt động như một hàm lai. Đối với các sai số nhỏ, nó cư xử như MSE (giúp hội tụ mượt mà quanh điểm cực tiểu). Nhưng đối với các sai số lớn (vượt qua một ngưỡng δ), nó chuyển sang hoạt động như Mean Absolute Error (MAE - Hàm tuyến tính $|x|$). Nhờ đó, Huber Loss tự động "cắt gọt" các gradient do nhiễu cảm biến gây ra, giúp mạng Q-Network duy trì sự ổn định tuyệt đối trong suốt quá trình huấn luyện.

c. Cấu hình Siêu tham số cốt lõi (Core Hyperparameters Tuning)

Để dẫn dắt Agent hội tụ về một chính sách tối ưu, hệ thống thiết lập các siêu tham số sau dựa trên thực nghiệm:

1. **Hệ số chiết khấu (Discount Factor) $\gamma = 0.99$:** Hệ số $\gamma \in [0, 1]$ định đoạt "tầm nhìn" của Agent. Việc đặt γ tiệm cận 1 bắt buộc Đặc vụ phải có tầm nhìn cực kỳ dài hạn (Long-term Vision). Agent sẽ không chỉ quan tâm đến phần thưởng trước mắt, mà phải xem xét tác động chuỗi của hành động dự báo hiện tại lên các diễn biến giao thông trong 2-3\$ giờ tới.
2. **Dung lượng Bộ nhớ Kinh nghiệm (Replay Buffer Size) $= 100,000$:** Bộ nhớ kích thước lớn giúp hệ thống lưu trữ được một lượng lịch sử đủ dài. Khi lấy mẫu ngẫu nhiên từ bộ nhớ này, hệ thống sẽ phá vỡ được sự tương quan chuỗi thời gian (Temporal Correlation) giữa các bước liên tiếp, đảm bảo các mẫu huấn luyện mang tính độc lập và phân phối đồng nhất (i.i.d).
3. **Kích thước Lô (Batch Size) $= 64$:** Đây là điểm cân bằng lý tưởng (Sweet spot) giữa hiệu suất tính toán của GPU và phương sai của Gradient. Batch quá nhỏ sẽ gây nhiễu hướng tối ưu, trong khi batch quá lớn sẽ khiến mô hình dễ hội tụ sớm vào các điểm cực tiểu cục bộ kém chất lượng.

5.5.3. Thiết kế Hàm Phần thưởng (Reward Shaping) - "Linh hồn" của sự thông minh

Nếu Mạng Nơ-ron (Q-Network) là "thể xác" và bộ nạp trọng số (Warm-start) là "bản năng", thì Hàm phần thưởng (Reward Function) chính là "linh hồn" định hình nên nhân cách và sự thông minh của Đặc vụ (Agent). Trong học tăng cường, Agent không phân biệt được đúng sai về mặt đạo đức hay vật lý; nó chỉ thuần túy tìm cách tối đa hóa tổng điểm thưởng. Do đó, việc thiết kế Hàm phần thưởng quyết định trực tiếp đến chiến lược hành vi của hệ thống.

a. Triết lý thiết kế: Tối ưu hóa hướng an toàn với Phạt không đối xứng (Asymmetric Penalty)

Trong các bài toán dự báo chuẩn, các hàm đánh giá (như Accuracy hay MSE) thường có tính đối xứng: Lỗi dự báo cao hơn thực tế (Over-prediction) và lỗi dự báo thấp hơn thực tế (Under-prediction) bị phạt như nhau. Tuy nhiên, khi áp dụng vào một hệ thống **Cảnh báo sớm giao thông (Early Warning System)**, tính đối xứng này trở nên cực kỳ nguy hiểm.

Dưới góc độ Trải nghiệm người dùng (UX) và An toàn nghiệp vụ:

- **Báo động giả (False Positive - Over-prediction):** Hệ thống dự báo kẹt xe nhưng thực tế đường thông thoáng. Người dùng có thể hơi phiền lòng vì phải đi đường vòng, nhưng rủi ro tổn thất thời gian là bằng không.
- **Bỏ lọt thảm họa (False Negative - Under-prediction):** Hệ thống báo đường thông thoáng nhưng thực tế là một vụ kẹt xe vỡ trận. Người dùng đi vào và mắc kẹt hàng giờ đồng hồ. Sự cố này sẽ lập tức phá hủy hoàn toàn niềm tin của người dùng vào ứng dụng.

Xuất phát từ triết lý "Thà báo nhầm còn hơn bỏ sót", đồ án xây dựng một Hàm phần thưởng phi tuyến tính và **Không đối xứng (Asymmetric Reward Shaping)** nhằm định hướng Agent hình thành một "Trực giác an toàn" (Safety Intuition).

b. Cơ chế Thưởng/Phạt chi tiết của Ma trận Trạng thái


Gọi y là nhãn thực tế (True Class) và $\hat{y}$ là nhãn Dự đoán (Predicted Class) với giá trị từ 0 đến 5. Hàm phần thưởng $R(y, \hat{y})$ được thiết kế với 4 tầng logic khắt khe, thể hiện rõ qua Ma trận phần thưởng (Hình 5.x):

1. **Thưởng chuẩn xác phân tầng (Stratified Match Bonus):** Khi Dự đoán dự đoán đúng hoàn toàn ($y = \hat{y}$), nó sẽ nhận được phần thưởng dương nhằm củng cố hành vi. Dựa trên ma trận, mức thưởng được phân thành hai nhóm: **15 điểm** cho các trạng thái giao thông từ thông thoáng đến hơi đông (Lớp 0, 1, 2) và **10 điểm** cho các trạng thái ùn tắc (Lớp 3, 4, 5). Việc phân tầng này thiết lập một bộ phóng điểm số vững chắc, giúp hệ thống duy trì sự ổn định khi mạng lưới hoạt động trong điều kiện bình thường.
2. **Khoan dung với Sai lệch gần (Near Miss Tolerance):** Giao thông là một dải động lực học liên tục, sự phân định giữa Lớp 2 (Hơi đông) và Lớp 3 (Đi chậm) đôi khi chỉ cách biệt vài km/h. Do đó, nếu Agent dự báo lệch đúng 1 cấp ($|\hat{y} - y| = 1$), hệ thống chỉ trừ một mức phạt rất nhẹ là **-1 điểm**. Cơ chế này tạo ra một vùng đệm linh hoạt, giúp Agent không bị "trùng phạt oan" bởi các nhiễu loạn ranh giới nhỏ của cảm biến IoT.
3. **Phạt sai lệch xa (Far Miss Penalty):** Khi độ chênh lệch cấp độ tăng lên ($|\hat{y} - y| \geq 2$), mức phạt bắt đầu gia tăng tuyến tính và lũy tiến (từ **-6**, **-9**, đến **-17 điểm**). Logic này đóng vai trò như một lực kéo, ép mạng Q-Network phải học và tôn trọng tính thứ bậc (Ordinal nature) của không gian trạng thái giao thông.
4. **PHẠT SINH TỬ (Severe Mismatch / Fatal Penalty):** Đây là "bức tường thép" mang tính sống còn của hệ thống cảnh báo. Quan sát khu vực được đóng khung ở góc dưới cùng bên trái của ma trận: Nếu thực tế xảy ra kẹt xe thảm họa (Lớp 4, Lớp 5) nhưng Agent lại chủ quan dự báo là đường thông thoáng (Lớp 0, Lớp 1), mức phạt

sẽ lao dốc xuống đáy, dao động từ **-19 điểm** đến mức cực đại **-25 điểm**. Mức phạt tàn khốc này áp đảo hoàn toàn mọi điểm thưởng tích lũy, tạo ra một nỗi "sợ hãi" toán học, ép Đặc vụ thả dục báo nhằm còn hơn bỏ sót thảm họa.

c. Kết quả hình thành Hành vi hệ thống

Trải qua hàng chục vạn chu kỳ cọ xát với ma trận phần thưởng này, Agent học được một bài học sinh tồn sâu sắc: Tránh bằng mọi giá vùng "Dưới dự báo" (Under-prediction) đối với các lớp thảm họa. Kết quả là, mạng Q-Network hình thành một biên giới quyết định (Decision Boundary) hơi thiên lệch một cách có chủ đích về phía an toàn. Đặc vụ trở nên cực kỳ nhạy bén với những dấu hiệu suy sụp vận tốc nhỏ nhất, sẵn sàng phát lệnh cảnh báo sớm. Sự bảo thủ này chính là chuẩn mực của các hệ thống an toàn quy mô lớn trong thế giới thực.



Hình 5.19: Ma trận Thưởng/Phạt không đối xứng

5.6. Đánh giá Thực nghiệm và So sánh (Empirical Evaluation & Benchmarking)

Trong nghiên cứu khoa học máy tính, việc đề xuất một kiến trúc mới chỉ thực sự có giá trị khi nó được chứng minh bằng các số liệu thực chứng khách quan (Empirical Evidence). Để đánh giá chính xác mức độ cải thiện mà kiến trúc học tăng cường lai (Hybrid RL) mang lại, đồ án thiết lập một môi trường thử nghiệm đối chứng (Benchmarking) nghiêm ngặt.

5.6.1. Thiết lập các mô hình đối chứng (Baselines)

Để đảm bảo tính công bằng (Apples-to-apples comparison), tất cả các mô hình trong thực nghiệm đều được đánh giá trên cùng một **Tập Kiểm thử (Hold-out Test Set)**. Tập kiểm thử này được chia cắt theo nguyên tắc thời gian tuyến tính (Chronological Split) để tuyệt đối ngăn chặn rò rỉ dữ liệu (Data Leakage), đóng vai trò như một môi trường tương lai chưa từng được các mô hình quan sát.

Hệ thống đánh giá được cấu thành từ 3 mô hình đại diện cho 3 triết lý tiếp cận khác nhau:

a. Mô hình Đối chứng 1: Học sâu Truyền thống (Vanilla LSTM)

- **Kiến trúc và Dữ liệu:** Đây là một mạng LSTM tiêu chuẩn, được huấn luyện trực tiếp trên tập dữ liệu thô (Raw Data) vốn dĩ bị mất cân bằng trầm trọng (Extreme Imbalance), sử dụng hàm mất mát Cross-Entropy tiêu chuẩn.
- **Mục đích đối chứng:** Mô hình này đại diện cho cách tiếp cận "ngây thơ" (Naive approach) phổ biến trong nhiều nghiên cứu cơ bản. Sự hiện diện của Vanilla LSTM đóng vai trò làm "Mức đáy" (Lower Bound). Kết quả của nó sẽ minh họa rõ nét sức tàn phá của bẫy **Thiên kiến lớp đa số (Majority Class Bias)**: Mô hình có thể đạt Accuracy cực cao nhưng lại hoàn toàn "mù" trước các vụ kẹt xe thảm họa.

b. Mô hình Đối chứng 2: Tiền huấn luyện Giám sát (Supervised Baseline)

- **Kiến trúc và Dữ liệu:** Đây chính là Trạm tiền huấn luyện (DNN) đã trình bày ở Mục 5.4. Mô hình này được trang bị "tận răng" các kỹ thuật tiền xử lý tối tân nhất của đồ án: Huấn luyện trên tập dữ liệu đã qua Cân bằng lai (CTGAN + Anchor-based), sử dụng Focal Loss và Ma trận Trọng số phạt (Class Weights).
- **Mục đích đối chứng:** Đây là đại diện cho **Giới hạn tối đa của Học có giám sát (Upper Bound of Supervised Learning)**. Việc đặt mô hình này làm đối chứng mang ý nghĩa biện chứng cực kỳ sâu sắc: Nó giúp trả lời trực tiếp câu hỏi cốt lõi của hội đồng: *"Tại sao phải tốn công làm Reinforcement Learning phức tạp, trong khi Supervised Learning đã làm rất tốt?"*. Chỉ khi Đặc vụ RL đánh bại được mô hình này ở khả năng phát hiện thảm họa, thì kiến trúc DQN mới thực sự có giá trị.

c. Mô hình Đề xuất: Đặc vụ Học tăng cường Lai (Hybrid Double DQN)

- **Kiến trúc và Dữ liệu:** Đây là "vũ khí tối thượng" của đồ án, kết tinh toàn bộ chuỗi pipeline kỹ thuật đã xây dựng:
 1. Dữ liệu đầu vào đi qua Bộ lọc tiền xử lý (Artifacts).
 2. Nạp trọng số Khởi động ấm (Warm-start) từ Mô hình 2 để bỏ qua giai đoạn thám hiểm ngẫu nhiên.
 3. Huấn luyện bằng thuật toán **Double DQN** với Replay Buffer.
 4. Tối ưu hóa chiến lược dựa trên **Hàm phần thưởng Không đối xứng (Asymmetric Reward Shaping)** phạt sinh tử các lỗi bỏ lọt thảm họa.

- Kỳ vọng:** Đề án kỳ vọng mô hình này không chỉ vượt qua Vanilla LSTM một cách tuyệt đối, mà còn phải hy sinh một chút độ chính xác ở các lớp thông thoáng (Lớp 0, 1) để đổi lấy sự bứt phá về năng lực Thu hồi (Recall) tại các Lớp thảm họa (Lớp 4, 5) so với Supervised Baseline.

5.6.2. Phân tích Chỉ số Hiệu năng (Metrics Analysis)

Trong việc đánh giá các mô hình học máy áp dụng cho hệ thống cảnh báo an toàn giao thông, việc lựa chọn đúng thước đo (Metric) là yếu tố tiên quyết. Một hệ thống có thể đạt điểm số toán học rất cao nhưng lại hoàn toàn thất bại trong việc bảo vệ người dùng nếu thước đo đó không phản ánh đúng rủi ro thực tế.

a. Phê phán chỉ số Accuracy và "Nghịch lý độ chính xác"

Đề án quyết định loại bỏ chỉ số Độ chính xác tổng thể (Accuracy) khỏi các tiêu chí đánh giá cốt lõi. Lý do xuất phát từ đặc tính mất cân bằng cực hạn của dữ liệu giao thông đô thị: hơn 90% mẫu dữ liệu thuộc trạng thái thông thoáng (Lớp 0, 1).

- Nếu một mô hình được huấn luyện sai lệch và luôn dự báo trạng thái "Thông thoáng" cho mọi trường hợp, mô hình đó vẫn đạt mức Accuracy trên 90%.
- Tuy nhiên, hệ thống này hoàn toàn vô dụng vì nó đã bỏ lọt 100% các vụ kẹt xe thảm họa (Lớp 4, 5). Đây chính là "Nghịch lý độ chính xác" (Accuracy Paradox) thường gặp trong dữ liệu chuỗi thời gian mất cân bằng, nơi các sai lầm nguy hiểm nhất bị che giấu bởi các dự báo đúng của lớp đa số.

b. Tầm quan trọng của Độ phủ (Recall) trong Cảnh báo thảm họa

Thay vì Accuracy, đề án tập trung tối ưu hóa chỉ số **Độ phủ (Recall)** cho các lớp kẹt xe nặng. Trong bài toán này, Recall đại diện cho khả năng "không bỏ sót" thảm họa. Đối với người dân và cơ quan quản lý, việc nhận một cảnh báo giả (dự báo kẹt nhưng thực tế đường thoáng - giảm Precision) vẫn ít gây thiệt hại hơn nhiều so với việc hệ thống báo đường thông nhưng thực tế người dùng bị kẹt cứng trong một vụ vỡ trận giao thông (bỏ sót thảm họa - giảm Recall).

c. Kết quả thực nghiệm và So sánh định lượng

Dữ liệu dưới đây được trích xuất trực tiếp từ các tệp nhật ký đánh giá (JSON evaluation logs) nằm trong thư mục [artifacts/rl/metrics/](#) của dự án. Việc sử dụng các tệp Artifacts này đảm bảo tính thực chứng và khả năng tái lập (Reproducibility) cao, cho phép các nghiên cứu sau này có thể đối chiếu chính xác kết quả trên cùng một tập Kiểm thử (Hold-out Test Set).

So sánh chỉ số Recall giữa các mô hình trên tập Kiểm thử

Mô hình đối chứng	Recall Lớp 0-1 (Thông thoáng)	Recall Lớp 2-3 (Ổn định)	Recall Lớp 4-5 (Thảm họa)


Mô hình 1: Vanilla LSTM	0.98	0.25	< 0.10
Mô hình 2: Supervised Baseline	0.85	0.72	0.68
Mô hình 3: Hybrid Double DQN (Đề xuất)	0.78	0.81	> 0.85

Nguồn dữ liệu: [artifacts/rl/metrics/rl_metrics_warmstart_manual_h15.json](#)

d. Biện luận kết quả

- Sự sụp đổ của Vanilla LSTM:** Đúng như dự báo, khi đối mặt với dữ liệu mất cân bằng, LSTM truyền thống gần như "mù" hoàn toàn trước thảm họa (Recall < 10%). Mô hình này ưu tiên dự báo lớp đa số để tối ưu hóa hàm Loss Cross-Entropy.
- Cú hích từ Supervised Baseline:** Nhờ kỹ thuật cân bằng dữ liệu CTGAN và Focal Loss, mô hình giám sát đã đạt được độ phủ khá (68%). Đây là giới hạn tối đa mà một mô hình học có giám sát thuần túy có thể đạt được trước khi bắt đầu đánh đổi quá nhiều về độ chính xác.
- Sự ưu việt của Hybrid Double DQN:** Mô hình đề xuất chứng minh sức mạnh áp đảo tại các lớp thảm họa với chỉ số Recall vọt lên mức **trên 85%**. Kết quả này khẳng định rằng sự kết hợp giữa "bản năng vật lý" (Warm-start) và "chiến lược an toàn" (Asymmetric Reward) đã ép Đặc vụ RL phải nhạy bén tối đa với các tín hiệu kẹt xe nặng. Đặc vụ thà chấp nhận rủi ro dự báo nhầm kẹt xe ở các lớp trung bình còn hơn phải gánh chịu mức phạt cực nặng (-20 điểm) khi bỏ lọt thảm họa Lớp 5.

So sánh hiệu năng thực tế: Khả năng nhận diện thảm họa giao thông



Hình 5.20: Biểu đồ so sánh hiệu năng thực tế giữa các mô hình

5.6.3. Giải mã "Hộp đen" và Tính minh bạch của hệ thống (Explainable AI với SHAP)

a. Vấn đề "Hộp đen" trong Học sâu (The Black-box Problem)

Mặc dù kiến trúc Hybrid Double DQN kết hợp mạng nơ-ron đa nhánh mang lại hiệu suất vượt trội trong việc tối ưu hóa Độ phủ (Recall) cho lớp thảm họa, nó vẫn không thoát khỏi bài toán kinh điển của Học sâu: Tính minh bạch bị che khuất.

Mạng Q-Network với hàng trăm ngàn tham số phi tuyến tính hoạt động như một "hộp đen" (Black-box). Khi hệ thống phát lệnh báo động "Sắp xảy ra vỡ trận giao thông (Lớp 5)", người quản trị hệ thống (cảnh sát giao thông, kỹ sư điều hành) sẽ lập tức đặt câu hỏi: "Dựa vào đâu mà AI lại đưa ra kết luận này?". Nếu không thể cung cấp lời giải thích logic mang tính vật lý, hệ thống sẽ vấp phải sự hoài nghi và bị từ chối triển khai trong thực tế do nghi ngờ mô hình chỉ đang "học vẹt" (Overfitting) các quy luật ngẫu nhiên.

b. Giải pháp SHAP (SHapley Additive exPlanations)

Để phá vỡ hộp đen, đồ án tích hợp lớp công nghệ **Trí tuệ nhân tạo có thể diễn giải (Explainable AI - XAI)**, sử dụng phương pháp **SHAP**.

Về mặt toán học, SHAP được xây dựng dựa trên Lý thuyết trò chơi hợp tác (Cooperative Game Theory). Nó xem mỗi đặc trưng đầu vào (ví dụ: vận tốc, độ trễ, thời gian) như một "người chơi" đóng góp vào "trò chơi" là giá trị dự báo cuối cùng của mạng Nơ-ron. Thuật toán tính toán giá trị Shapley để phân bổ công bằng tầm ảnh hưởng biên (Marginal Contribution) của từng đặc trưng:

$$\phi(z') = \phi_0 + \sum_{i=1}^M \phi_i(z'_i)$$

Trong đó, $\phi(z')$ là mô hình giải thích, ϕ_0 là giá trị kỳ vọng cơ sở, và ϕ_i là giá trị SHAP của đặc trưng thứ i . Giá trị ϕ_i mang dấu dương nghĩa là đặc trưng đó đẩy dự báo lên mức kẹt xe nặng hơn, và ngược lại.

c. Minh chứng thực tiễn: Cấu trúc logic của một cảnh báo thảm họa

Bằng cách áp dụng SHAP để bóc tách một ca cảnh báo Thảm họa (Lớp 5) từ mô hình RL, hệ thống đã trích xuất được sự đóng góp cục bộ (Local Explanation) của các biến số:

- Dẫn dắt bởi quy luật vật lý, không phải nhiễu loạn:** Kết quả bóc tách cho thấy tín hiệu đẩy dự báo lên Lớp 5 mạnh mẽ nhất đến từ việc biến số **current_speed_kmh** (Vận tốc dòng xe) giảm sâu một cách bất thường, kết hợp với sự tăng vọt cục bộ của **traffic_index** (Chỉ số ùn tắc).
- Sự tương tác phi tuyến (Feature Interaction):** SHAP phát hiện rằng mô hình không chỉ nhìn vào vận tốc hiện tại. Giá trị SHAP của lớp 5 chỉ thực sự bùng nổ khi "Vận tốc giảm" xảy ra đồng thời với biến bối cảnh **is_rush_hour = True** (Giờ cao điểm) hoặc **weather_condition** xấu.
- Khử bỏ học vẹt (Anti-Memorization):** Các biến mang tính định danh tĩnh (như **segment_id** hay **road_length**) có giá trị SHAP đóng góp xoay quanh mức \$0\$. Điều này chứng minh Đặc vụ DQN đã thực sự học được Động lực học dòng chảy giao thông (Traffic Flow Dynamics) dựa trên các nguyên lý vật lý nhân quả, thay vì chỉ cố gắng ghi nhớ và học vẹt các thuộc tính hình học của một đoạn đường cụ thể.

Sự minh bạch hóa này biến kiến trúc "Hộp đen" thành một "Hộp kính" (Glass-box). Nó đảm bảo rằng mọi quyết định điều hướng và cảnh báo của hệ thống khi triển khai vào môi trường thực tế (Production) đều có thể được truy vết, kiểm toán và giải thích một cách thuyết phục cho con người.

(Ghi chú chèn ảnh: Tại đây trình bày [Hình 5.z: Biểu đồ SHAP Waterfall], minh họa chi tiết mức độ đóng góp của từng đặc trưng đầu vào của mô hình lên mức Thẩm họa Lớp 5).

5.7. Hạn chế của Hệ thống đề xuất và Hướng phát triển

Một hệ thống Trí tuệ Nhân tạo dù được thiết kế hoàn chỉnh đến đâu trong môi trường phòng thí nghiệm cũng sẽ bộc lộ những giới hạn nhất định khi phải đối mặt với áp lực vận hành thực tế. Việc nhận diện rõ các giới hạn này là tiền đề quan trọng để vạch ra lộ trình nâng cấp hệ thống trong tương lai.

5.7.1. Hạn chế về Độ trễ Xử lý quy mô lớn (Inference Latency at Scale)

a. Phân tích Nút thắt cổ chai (Bottleneck Analysis) Kiến trúc Hybrid Double DQN đề xuất đã đạt được độ chính xác và độ phủ (Recall) xuất sắc, nhưng sự đánh đổi lại nằm ở chi phí thời gian tính toán (Computational Overhead).

Hiện tại, luồng xử lý suy luận (Inference Pipeline) đang được vận hành hoàn toàn trên môi trường Python thuần túy. Khi một luồng dữ liệu thời gian thực truyền về từ hệ thống cảm biến, nó bắt buộc phải đi qua một chuỗi các bước trung gian tuần tự:

1. Tiền xử lý và điền khuyết (`ffill`).
2. Đi qua "Bản hợp đồng dữ liệu" (`StandardScaler` & `LabelEncoders`).
3. Đưa vào mạng Q-Network đa nhánh (qua luồng LSTM tính toán chuỗi, giải mã Embedding, và FNN xử lý đặc trưng tĩnh).

Trong bối cảnh thử nghiệm quy mô nhỏ, độ trễ này (tính bằng mili-giây) là hoàn toàn có thể chấp nhận được. Tuy nhiên, nếu hệ thống được triển khai cho toàn bộ mạng lưới giao thông của một siêu đô thị (ví dụ: lên tới hàng vạn đoạn đường cùng cần dự báo đồng thời mỗi 15 phút), sự chồng kênh của framework PyTorch cùng với giới hạn đa luồng của Python (Global Interpreter Lock - GIL) sẽ tạo ra một độ trễ hệ thống (Inference Latency) đáng kể, khó đáp ứng được các tiêu chuẩn khắt khe (SLA) của một API cảnh báo thời gian thực.

b. Hướng phát triển: Tối ưu hóa với ONNX Runtime và TensorRT Để giải quyết triệt để nút thắt cổ chai về mặt hiệu năng hệ thống (Backend Performance), hướng phát triển ưu tiên trong giai đoạn tiếp theo là tối ưu hóa và biên dịch lại mô hình học sâu.

Thay vì giữ nguyên trọng số ở định dạng PyTorch gốc (`.pt`), toàn bộ kiến trúc mạng Q-Network sẽ được xuất (export) sang chuẩn **ONNX (Open Neural Network Exchange)**. Đây là một định dạng trung gian giúp tối ưu hóa đồ thị tính toán (Computation Graph) bằng cách gộp các toán tử (Operator Fusion) và loại bỏ các phép tính dư thừa.

Để vắt kiệt sức mạnh xử lý song song, đồ án đề xuất triển khai môi trường suy luận bằng **NVIDIA TensorRT**.

- TensorRT sẽ biên dịch trực tiếp đồ thị ONNX thành mã máy tối ưu hóa riêng cho từng kiến trúc phần cứng GPU cụ thể.
- Kỹ thuật lượng tử hóa (Quantization) có thể được áp dụng để giảm độ chính xác của trọng số từ **FP32** (Số thực dấu phẩy động 32-bit) xuống **FP16** hoặc **INT8** mà vẫn bảo toàn được chỉ số Recall ở các lớp thăm họa.

Khi đó, mô hình suy luận tốc độ cao này sẽ được đóng gói gọn gàng trong các container độc lập (sử dụng Docker) để dễ dàng nhân bản (scale) và tích hợp vào các hệ thống quản lý hạ tầng ứng dụng vi dịch vụ (Microservices), biến hệ thống từ một mô hình nghiên cứu thành một sản phẩm sẵn sàng phục vụ hàng triệu người dùng (Production-ready).

5.7.2. Khoảng cách giữa Môi trường Mô phỏng và Thực tế (Sim-to-Real Gap)

a. Phân tích Bản chất của sự sai lệch (The Nature of Sim-to-Real Gap)

Mặc dù hệ thống đã sử dụng kiến trúc Hybrid Resampling (nhấn mạnh vào mạng sinh tạo Sequence-CTGAN) kết hợp với Màn lọc Hậu kiểm Vật lý (Physical Sanity Filter) để tạo ra Tập dữ liệu Vàng cực kỳ chất lượng, chúng ta vẫn phải nhìn nhận một thực tế mang tính toán học: Dữ liệu nhân tạo bao giờ cũng có một độ "sạch" (Cleanliness) nhất định về mặt thống kê.

Cụ thể, CTGAN học cách xấp xỉ phân phối xác suất chung của các thảm họa trong quá khứ để sinh ra các kịch bản mới. Tuy nhiên, môi trường giao thông thực tế lại chứa đựng tính hỗn loạn (Chaos) không thể lường trước. Các thiết bị cảm biến IoT ngoài trời thường xuyên gặp phải những nhiễu loạn cực đoan (Extreme Noise) hoàn toàn nằm ngoài phân phối chuẩn:

- Tín hiệu GPS bị nhiễu sóng khi thời tiết cực xấu làm vận tốc báo về nhảy vọt vô lý.
- Lỗi ngắt kết nối phần cứng khiến dữ liệu bị gián đoạn và xuất hiện các chuỗi giá trị \$0\$ liên tục.
- Những sự cố tai nạn nghiêm trọng mang tính "Thiên nga đen" (Black Swan events) gây ra sự sụt giảm vận tốc tức thời, vi phạm cả tính mượt mà thời gian (Temporal Smoothness) mà màn lọc vật lý đã thiết lập.

Khi Đặc vụ Học tăng cường (DQN Agent) được huấn luyện hoàn toàn trong Môi trường Gymnasium dựa trên tập dữ liệu tĩnh này (Offline Reinforcement Learning), nó có thể sẽ bị "sốc" hoặc lúng túng khi đối mặt với những loại nhiễu loạn chưa từng có trong tập huấn luyện. Sự chênh lệch về phân phối nhiễu này được gọi là khoảng cách Sim-to-Real (Simulation-to-Reality Gap).

b. Hướng phát triển: Học tăng cường Trực tuyến (Online Reinforcement Learning)

Để thu hẹp khoảng cách Sim-to-Real và biến Đặc vụ thành một thực thể thực sự "sống" cùng dòng chảy giao thông, hướng nâng cấp bắt buộc trong tương lai là chuyển dịch từ mô hình Offline sang cơ chế **Học tăng cường Trực tuyến (Online Reinforcement Learning / Continuous Learning)**.

Thay vì đóng băng trọng số mạng Q-Network sau khi triển khai (Deployment), hệ thống sẽ được thiết kế một pipeline phản hồi vòng kín (Closed-loop Feedback):

1. **Dự báo và Ghi nhận:** Hệ thống thực hiện dự báo trạng thái tương lai và lưu lại quyết định này.
2. **Khớp nổi thực tế (Ground-truth Matching):** Khi thời gian thực trôi qua đúng bằng khung cửa sổ dự báo (ví dụ \$15\$ phút sau), hệ thống tự động đối chiếu dự báo cũ với nhãn thực tế thu được từ luồng cảm biến dòng (Streaming data).
3. **Cập nhật động lực (Dynamic Fine-tuning):** Dựa trên mức độ sai lệch, hệ thống sẽ gọi lại Hàm phần thưởng không đối xứng (Asymmetric Reward) để tính toán điểm số Thưởng/Phạt, nạp mẫu (Transition) này vào một Replay Buffer dung lượng nhỏ mang tính cục bộ (Local Buffer), và thực hiện một bước truyền ngược (Backpropagation) để tinh chỉnh nhẹ các trọng số biên của Agent.

Cơ chế Online RL này hoạt động tương tự như một hệ thống "Miễn dịch học tập". Nó cho phép Mạng Nơ-ron liên tục thích nghi với các loại nhiễu cảm biến mới, điều chỉnh theo sự thay đổi về hành vi di chuyển của người dân theo mùa (Concept Drift), và đảm bảo hiệu năng cảnh báo thảm họa không bao giờ bị suy thoái theo thời gian.

5.7.3. Giới hạn Nhận thức Không gian và Định hướng Đô thị (Spatial Awareness & Graph Evolution)

a. Phân tích Nút thắt Cấu trúc: Sự vắng mặt của Động lực học Không gian

Kiến trúc Hybrid Double DQN hiện tại, với cốt lõi là mạng LSTM, sở hữu năng lực xử lý chuỗi thời gian (Temporal Dynamics) vô cùng mạnh mẽ. Nó có thể nắm bắt hoàn hảo quán tính của một dòng xe đang chậm dần trên một đoạn đường cụ thể. Tuy nhiên, giới hạn cốt lõi của hệ thống nằm ở khả năng **Nhận thức không gian bối cảnh (Spatial Context Awareness)**.

Trong thực tế, mạng lưới giao thông đô thị là một hệ thống có tính liên kết tô-pô (Topological Connectivity) cực kỳ chặt chẽ. Hiện tượng ùn tắc không bao giờ đứng yên; nó lan truyền theo "Hiệu ứng gợn sóng" (Ripple Effect) hoặc "Dội ngược" (Spillback). Một vụ kẹt xe vỡ trận ở ngã tư \$A\$ gần như chắc chắn sẽ gây ra hiệu ứng domino, làm tê liệt tuyến đường dẫn vào \$B\$ chỉ \$5\$ đến \$10\$ phút sau đó.

Mô hình hiện tại tiếp cận các đoạn đường (Segments) một cách tương đối độc lập, hoặc chỉ liên kết lỏng lẻo thông qua việc mã hóa định danh (Segment ID Embedding). Nó thiếu một cơ chế học sâu toán học để hiểu rõ *khoảng cách vật lý* và *hướng di chuyển* giữa các đoạn đường này.

b. Bước đệm hiện tại: Cơ chế Không gian Dự phòng (Global Spatial Fallback)

Trong khuôn khổ đồ án, hệ thống đã thực hiện một bước đệm sơ khởi để giải quyết vấn đề không gian này thông qua cơ chế **Global Spatial Fallback**.

Cơ chế này được kích hoạt như một màng lưới an toàn (Safety Net) trong khâu tiền xử lý dữ liệu: Khi một đoạn đường bị mất tín hiệu hoàn toàn từ cảm biến IoT, hệ thống sẽ không để giá trị rỗng (NaN) làm sập mô hình, mà tiến hành quét bán kính không gian xung quanh để "mượn" các đặc trưng tốc độ/độ trễ từ các đoạn đường lân cận nhằm nội suy trạng thái.

Dù đây là một giải pháp Heuristic xuất sắc để đảm bảo tính sẵn sàng cao (High Availability) của Data Pipeline, nó vẫn chỉ là một phép xấp xỉ thống kê, chưa phải là cơ chế học được mối quan hệ nhân quả không gian phức tạp.


c. Hướng phát triển Đột phá: Tích hợp Mạng Nơ-ron Đồ thị (Graph Neural Networks - GNN)

Để giải quyết triệt để bài toán này, định hướng phát triển tối hậu của hệ thống là chuyển đổi từ kiến trúc dạng chuỗi (Sequence-based) sang kiến trúc Không gian - Thời gian (Spatio-Temporal Architecture) bằng cách tích hợp **Mạng Nơ-ron Đồ thị (Graph Neural Networks - GNN)**.

Mạng lưới đường bộ sẽ được mô hình hóa thành một đồ thị động có hướng $G = (V, E)$, trong đó:

- **Tập đỉnh V (Vertices):** Đại diện cho các ngã tư hoặc các đoạn đường.
- **Tập cạnh E (Edges):** Đại diện cho sự kết nối vật lý và hướng di chuyển của dòng xe, được biểu diễn qua Ma trận kề (Adjacency Matrix).

Việc ứng dụng các kiến trúc như **Spatio-Temporal Graph Convolutional Networks (STGCN)** hoặc **Graph Attention Networks (GAT)** sẽ cho phép Đặc vụ DQN quan sát được "bức tranh toàn cảnh". GNN sẽ học cách truyền trọng số thông tin (Message Passing) từ đỉnh A sang đỉnh B , giúp Agent không chỉ dự báo kẹt xe dựa trên dữ liệu quá khứ của chính đoạn đường đó, mà còn dựa trên làn sóng ùn tắc đang cuộn tới từ các ngã tư lân cận. Sự kết hợp giữa GNN (bắt không gian) và RL (tối ưu chiến lược quyết định) sẽ đẩy độ chính xác của hệ thống cảnh báo sớm lên mức hoàn hảo.



Hình 5.21: Tích hợp Mạng Nơ-ron Đồ thị (GNN)